Universidad de Las Américas

Facultad de Ingeniería y Ciencias Aplicadas

Maestría en Inteligencia Artificial Aplicada

Tema:

Sistema inteligente para el control de cocción de donas mediante visión artificial y aprendizaje automático basado en colorimetría.

Nombres y Apellidos del estudiante:

Edwin Gabriel Naranjo Velastegui

Fecha:

Quito, Ecuador

11 de marzo de 2025

Resumen

El presente trabajo de titulación aborda la problemática de la evaluación subjetiva del punto de cocción de donas en la panadería Micro Quito y Panadería, donde la inspección visual manual genera variabilidad en la calidad del producto final. Se desarrolló un sistema inteligente de clasificación basado en visión artificial y aprendizaje automático, utilizando la plataforma low-code Teachable Machine. Se recolectaron **1,035 imágenes** distribuidas en tres clases (insuficiente, óptima, sobrecocción), todas capturadas bajo condiciones estandarizadas de iluminación y distancia. Tras identificar un desbalance significativo (41.2% en la clase insuficiente), se balanceó el dataset reduciendo dicha clase a 320 imágenes, igualando las tres categorías. Se incrementaron las épocas de entrenamiento de 50 a 150, manteniendo el batch size en 16 y la tasa de aprendizaje en 0.001. El modelo ajustado alcanzó una **precisión global del 100%** en un conjunto de prueba de 141 imágenes, con una matriz de confusión diagonal perfecta. Los resultados demuestran que, con datos de calidad y un diseño cuidadoso, es posible obtener un sistema de apoyo a la decisión altamente confiable para el control de calidad en PYMES. El prototipo fue desplegado como aplicación web con TensorFlow.js y el código se encuentra disponible en un repositorio de GitHub.

Palabras clave: Visión artificial; aprendizaje automático; control de calidad; colorimetría; donas; Teachable Machine.

Abstract

This thesis addresses the problem of subjective evaluation of donut cooking doneness at Micro Quito y Panadería bakery, where manual visual inspection generates variability in final product quality. An intelligent classification system based on computer vision and machine learning was developed using the low-code platform Teachable Machine. A total of **1,035 images** were collected across three classes (undercooked, optimal, overcooked), all captured under standardized lighting and distance conditions. After identifying a significant

imbalance (41.2% in the undercooked class), the dataset was balanced by reducing that class to 320 images, equalizing the three categories. Training epochs were increased from 50 to 150, keeping batch size at 16 and learning rate at 0.001. The adjusted model achieved **100% global accuracy** on a test set of 141 images, with a perfect diagonal confusion matrix. The results demonstrate that, with quality data and careful design, it is possible to obtain a highly reliable decision support system for quality control in SMEs. The prototype was deployed as a web application with TensorFlow.js and the code is available in a GitHub repository.

Keywords: Computer vision; machine learning; quality control; colorimetry; donuts; Teachable Machine.

---

1. Introducción

1.1. Identificación y descripción del problema o necesidad

Actualmente, el proceso de evaluación del punto de cocción de las donas en Micro Quito y Panadería se realiza de forma visual y manual por parte del personal operativo. Este método depende de la experiencia del operario, de las condiciones de iluminación y de la carga de trabajo, lo que introduce un alto nivel de subjetividad en la decisión de liberar o no el producto para la venta. La falta de un criterio objetivo y estandarizado provoca variaciones en la colorimetría del producto final, generando donas crudas, sobrecocidas o con diferencias visibles entre lotes, lo que afecta la percepción de calidad del consumidor.

Análisis de Causas (5 Porqués):
Para la determinación de las causas que originan la problemática identificada, se aplicó la metodología de análisis de causa raíz "5 Porqués". A partir del análisis del proceso actual de fritura y control de calidad de las donas, se identificaron las siguientes causas principales:

- Dependencia de la inspección visual del operario para determinar el punto de cocción, lo que introduce variabilidad subjetiva en la evaluación del producto.
- Ausencia de parámetros cuantificables y estandarizados de colorimetría que definan objetivamente los niveles de cocción aceptables.
- Incremento proyectado de la producción que supera la capacidad de control manual del proceso, especialmente ante la futura implementación de una freidora especializada.
- Variabilidad en las condiciones de iluminación y tiempos de exposición durante el proceso de fritura, lo que dificulta una evaluación consistente del color final del producto.
- Falta de herramientas tecnológicas accesibles que permitan apoyar la toma de decisiones en tiempo real durante el proceso productivo.

La aplicación de la metodología de los 5 Porqués permitió concluir que la causa raíz del problema no se limita a errores humanos individuales, sino a la inexistencia de un sistema de apoyo basado en criterios objetivos y reproducibles para el control del nivel de cocción.

Consecuencias del problema:
La ausencia de un sistema estandarizado ha generado impactos operativos y productivos. A nivel operativo, se estima que aproximadamente entre el 10 % y el 15 % de las donas producidas semanalmente (más de 150 unidades) presentan desviaciones en su nivel de cocción (producto crudo o sobrecocido), lo que ocasiona reprocesos, desperdicio de materia prima y un incremento en los tiempos de producción. Asimismo, el tiempo destinado a la inspección manual del producto incrementa la carga operativa del personal entre un 15 % y un 20 %, afectando la capacidad de respuesta ante una mayor demanda. Desde una perspectiva estratégica, la proyección de triplicar la producción de donas incrementa el riesgo de errores en el control de calidad si se mantiene el método manual actual.

1.2. Descripción de la organización

- **Identificación de la organización:** Micro Quito y Panadería es una empresa con aproximadamente veinte años de trayectoria, ubicada en el sector de Kennedy, al norte de la ciudad de Quito. Es una empresa del sector alimenticio (panadería y repostería).
- **Misión y Visión:**
    - **Misión:** Ofrecer productos de panadería de calidad superior a precios accesibles, utilizando materia prima seleccionada y priorizando una experiencia positiva para el cliente mediante un servicio cercano, un ambiente agradable y procesos productivos eficientes.
    - **Visión:** Consolidarse como una panadería referente en la producción de alimentos de alta calidad, fortaleciendo su presencia en el mercado actual y proyectando una futura expansión a nivel nacional.
- **Estructura organizacional:** [Se requiere un organigrama y la identificación de departamentos. El proyecto se centra en el área de producción].
- **Productos y servicios:** La organización se dedica a la elaboración y comercialización de productos de panificación y repostería, contando con un portafolio diverso que incluye más de veinticinco variedades de pan, alrededor de quince tipos de pasteles y múltiples productos de repostería, incluyendo donas.
- **Segmento de mercado:** Mercado local en el sector de Kennedy, Quito.
- **Departamento/Área del problema:** El problema se localiza en el **área de producción**, específicamente en el proceso de fritura de donas.

---

2. Análisis de posibles soluciones

2.1. Identificación y selección de la mejor solución

Se han planteado dos alternativas de solución basadas en inteligencia artificial para abordar el problema de control de cocción:

Propuesta A: Sistema basado en Teachable Machine y TensorFlow.js

- **Objetivo:** Desarrollar un sistema de clasificación visual del nivel de cocción de donas utilizando un modelo entrenado con imágenes etiquetadas.
- **Descripción:** Se empleará la herramienta low-code Teachable Machine para entrenar un modelo de clasificación supervisada a partir de imágenes capturadas del producto en diferentes estados de cocción. El modelo será exportado a TensorFlow.js y desplegado en una aplicación web que permita capturar imágenes en tiempo real desde la cámara de un dispositivo móvil o tablet.
- **Arquitectura:** Cliente web – modelo local en navegador.

Propuesta B: Modelo de visión artificial desarrollado en Python

- **Objetivo:** Implementar un modelo de red neuronal convolucional (CNN) para la clasificación del nivel de cocción.
- **Descripción:** Se desarrollará un modelo CNN utilizando librerías como TensorFlow/Keras y OpenCV, entrenado con el mismo conjunto de imágenes. La solución requeriría un backend que procese las imágenes y devuelva la clasificación al usuario.
- **Arquitectura:** Cliente web – servidor backend – modelo de IA.

Comparación de alternativas (basado en ISO/IEC 25010):

Criterio	Peso	Propuesta A (Teachable Machine)	Propuesta B (CNN en Python)
Funcionalidad	20%	4	5
Usabilidad	20%	5	3

Criterio	Peso	Propuesta A (Teachable Machine)	Propuesta B (CNN en Python)
Fiabilidad	15%	4	4
Mantenibilidad	15%	5	3
Portabilidad	15%	5	3
Costo de implementación	15%	5	2
Total	**100%**	**4.6**	**3.5**

Selección: Se selecciona la **Propuesta A** por su mayor viabilidad técnica, menor costo, rapidez de implementación y facilidad de uso en el entorno operativo de una PYME.

2.2. Impacto del proyecto en la sociedad

El proyecto aporta beneficios tanto para la organización como para la sociedad en general:

- **Económico:** Reducción de desperdicios de materia prima (donas crudas o quemadas) y optimización de tiempos de producción, lo que se traduce en un ahorro económico para la panadería.
- **Social:** Mejora la percepción de calidad y consistencia del producto para los consumidores locales. Además, al ser una solución low-cost y accesible, puede servir como modelo para otras pequeñas y medianas empresas (PYMES) del sector alimenticio que busquen digitalizar sus procesos de control de calidad sin realizar grandes inversiones.
- **Tecnológico:** Demuestra la aplicabilidad práctica de herramientas de inteligencia artificial de bajo código en contextos productivos reales,

fomentando la transferencia de tecnología y la innovación en entornos con recursos limitados.

- **Ambiental:** Al reducir el desperdicio de alimentos, se contribuye indirectamente a una producción más sostenible.

---

3. Objetivos

3.1. Objetivo General

Desarrollar un sistema inteligente de clasificación del nivel de cocción de donas mediante técnicas de visión artificial y aprendizaje automático, basado en análisis colorimétrico, para apoyar la toma de decisiones objetivas en el control de calidad del proceso productivo de Micro Quito y Panadería.

3.2. Objetivos Específicos

1. Analizar el proceso actual de evaluación de cocción de donas en la panadería para definir los requerimientos funcionales y técnicos del sistema inteligente durante las primeras dos semanas del proyecto.
2. Diseñar un conjunto de clases de cocción basadas en parámetros de colorimetría, estableciendo rangos de aceptación y criterios de liberación del producto mediante técnicas de clasificación supervisada.
3. Desarrollar y entrenar un modelo de visión artificial utilizando la herramienta low-code Teachable Machine, empleando un conjunto de imágenes representativas del proceso productivo.
4. Evaluar el desempeño del modelo mediante métricas de clasificación como precisión global (accuracy), matriz de confusión y precisión por clase, comparando al menos dos alternativas técnicas.
5. Implementar el sistema en un entorno web accesible desde dispositivos móviles y de escritorio, permitiendo su uso operativo por parte del personal en tiempo real durante el proceso de fritura.

4. Alcance

4.1. Alcance de la solución seleccionada

- **Qué aborda el proyecto:**
  - El desarrollo de un sistema de clasificación de imágenes para determinar el nivel de cocción de donas (insuficiente, óptima, sobrecocción) basado en su color superficial.
  - La implementación de un prototipo funcional en un entorno web, utilizando un modelo entrenado con Teachable Machine y desplegado con TensorFlow.js.
  - La evaluación del modelo en un entorno controlado que simule las condiciones de la planta de producción.
- **Qué no aborda:**
  - No se integrará con el sistema ERP o de inventarios de la empresa.
  - No se desarrollará un modelo de red neuronal desde cero; se utilizará la plataforma Teachable Machine que emplea transfer learning.
  - No se implementará un sistema de control automático de la freidora (por ejemplo, para retirar las donas automáticamente).
  - No se abordará la calibración automática de la cámara ante cambios extremos de iluminación, aunque se documentarán las condiciones óptimas de uso.
- **Supuestos considerados:**
  - La empresa cuenta con dispositivos móviles o tablets con cámara y acceso a un navegador web moderno.
  - El personal operativo puede ser capacitado brevemente para el uso de la herramienta.
  - Las condiciones de iluminación en el área de producción pueden ser estandarizadas hasta un nivel que permita la captura consistente de imágenes.

4.2. Limitaciones y restricciones del proyecto

- **Limitaciones:**
  - El modelo se entrenó con un conjunto de datos limitado a las condiciones específicas de la panadería, lo que podría afectar su capacidad de generalización a otros entornos.
  - El sistema es una herramienta de apoyo a la decisión y no reemplaza el juicio final del operario.
- **Restricciones:**
  - La solución debe funcionar en navegadores web con soporte para HTML5 y JavaScript (para TensorFlow.js).
  - No se incurrirá en costos de licenciamiento de software; se utilizarán herramientas gratuitas (Teachable Machine, TensorFlow.js, GitHub Pages u hospedaje similar).
  - El desarrollo del proyecto debe completarse en el período académico establecido (16 semanas).

---

5. Planificación y costos del proyecto

Marco de gestión del proyecto: Se utilizará un enfoque ágil simplificado (similar a Scrum o Kanban) para la gestión de tareas, con entregables al final de cada fase.

Planificación y Cronograma:

Fase	Actividad principal	Descripción de actividades	Fecha inicio	Fecha fin	Entregable
Fase 1	Análisis y planificación	Levantamiento de información del proceso productivo, análisis del problema,	12/01	25/01	Documento de análisis del problema y requerimientos

Fase	Actividad principal	Descripción de actividades	Fecha inicio	Fecha fin	Entregable
		definición de requerimientos funcionales y no funcionales, y revisión bibliográfica inicial.			
Fase 2	Recolección y preparación de datos	Captura de imágenes de donas en distintos niveles de cocción, etiquetado de datos y validación de calidad del conjunto de imágenes.	26/01	08/02	Dataset de imágenes documentado
Fase 3	Diseño de la solución	Definición de clases de cocción, arquitectura del sistema, selección de herramientas y diseño del flujo de la aplicación web.	09/02	22/02	Documento de diseño y arquitectura
Fase 4	Desarrollo del modelo de IA	Entrenamiento del modelo de clasificación mediante Teachable Machine.	23/02	08/03	Modelos entrenados y documentados
Fase 5	Evaluación y validación	Evaluación del desempeño del modelo mediante métricas de clasificación (precisión, matriz	09/03	22/03	Resultados de evaluación y análisis comparativo

Fase	Actividad principal	Descripción de actividades	Fecha inicio	Fecha fin	Entregable
		de confusión) y comparación de alternativas.			
Fase 6	Implementación del sistema	Despliegue del modelo seleccionado en un entorno web accesible desde dispositivos móviles y de escritorio.	23/03	05/04	Sistema web funcional
Fase 7	Documentación final	Redacción del informe final del proyecto, integración de resultados, conclusiones y recomendaciones.	06/04	13/04	Documento final del proyecto
Fase 8	Preparación de defensa	Elaboración de presentación, revisión final y preparación para la defensa del proyecto.	14/04	16/04	Defensa del proyecto

Costos del proyecto:

- **Recursos Humanos:** Horas dedicadas por los estudiantes (costo no monetario, académico).
- **Software:** Gratuito (Teachable Machine, TensorFlow.js, editor de código, GitHub Pages).
- **Hardware:** Dispositivos móviles/cámaras ya disponibles en la empresa. Computadoras personales de los estudiantes.

- **Otros:** Ninguno significativo.

---

6. Descripción de estudios realizados

Se realizó una búsqueda bibliográfica sistemática en bases de datos académicas como IEEE Xplore, SpringerLink, Scopus y Google Scholar, utilizando cadenas de búsqueda como "computer vision" AND "food quality", "colorimetry" AND "machine learning", y "deep learning" AND "food inspection", con un filtro de años (2019-2024). Los estudios seleccionados demuestran una tendencia creciente en el uso de visión artificial para control de calidad en alimentos.

Síntesis crítica del estado del arte:
La literatura científica analizada evidencia que el uso de técnicas de visión artificial y aprendizaje automático se ha consolidado como una alternativa efectiva para el control de calidad en productos alimentarios, especialmente en procesos donde la evaluación visual del color es determinante (Lin et al., 2021). El color superficial constituye un indicador directo del estado de cocción y de la percepción de calidad del consumidor (Ayustaningwarno et al., 2021).

Diversos estudios demuestran que los sistemas de visión artificial permiten transformar una evaluación subjetiva en un proceso cuantificable y reproducible, reduciendo la dependencia del juicio humano (Brosnan & Sun, 2019). En cuanto a las técnicas de IA, las redes neuronales convolucionales (CNN) son las más utilizadas para tareas de clasificación de imágenes. Sin embargo, la literatura señala que entrenar modelos desde cero requiere grandes volúmenes de datos y capacidad computacional, lo cual es una barrera para PYMES (Kamilaris & Prenafeta-Boldú, 2018). En este sentido, el uso de modelos preentrenados y estrategias de transferencia de aprendizaje (transfer learning) se presenta como una alternativa viable.

Un aspecto crítico identificado es la brecha entre soluciones académicas y su implementación práctica en pequeñas organizaciones (Wuest et al., 2016). En respuesta, estudios recientes destacan el potencial de las plataformas de IA de

bajo código (low-code) para reducir barreras técnicas y facilitar la adopción de estas tecnologías (Rai et al., 2022). Este hallazgo justifica la selección de Teachable Machine como herramienta principal para el proyecto, alineándose con la necesidad de una solución accesible, de bajo costo y fácil de implementar en un entorno productivo real como el de Micro Quito y Panadería.

---

7. Desarrollo del proyecto

El desarrollo del proyecto se llevó a cabo siguiendo un enfoque metodológico basado en fases secuenciales, desde el análisis del problema hasta la implementación de un prototipo funcional, utilizando herramientas de inteligencia artificial de bajo código para garantizar la viabilidad técnica y operativa en el contexto de una PYME.

7.1. Diseño de la solución

- **Enfoque metodológico aplicado:** Se utilizó un enfoque de desarrollo iterativo e incremental, con fases claramente definidas que permitieron la retroalimentación y ajuste continuo del proyecto.
- **Fases del proyecto:** Las fases del proyecto corresponden a las detalladas en la planificación (Análisis, Datos, Diseño, Desarrollo, Evaluación, Implementación, Documentación).
- **Actividades realizadas:**
    - Levantamiento de información del proceso de fritura en Micro Quito y Panadería.
    - Captura y etiquetado de un conjunto de imágenes de donas en diferentes estados de cocción (insuficiente, óptima, sobrecocción), todas bajo condiciones estandarizadas de iluminación y distancia.
    - Definición de la arquitectura del sistema: Aplicación web cliente-side que carga un modelo de TensorFlow.js para realizar inferencia en tiempo real desde la cámara del dispositivo.

    - Selección de herramientas: Teachable Machine para el entrenamiento del modelo, TensorFlow.js para el despliegue, y HTML/CSS/JavaScript para la interfaz de usuario.
- **Criterios de evaluación:** Precisión global, matriz de confusión, precisión por clase.

7.2. Desarrollo de la solución

7.2.1 Descripción de los datos

El proyecto se fundamenta en el uso de datos visuales primarios, consistentes en imágenes digitales en formato RGB capturadas directamente durante el proceso de fritura de donas en el entorno productivo real. La naturaleza primaria del dataset garantiza representatividad contextual, ya que las imágenes reflejan condiciones reales de operación y no escenarios simulados.

Las imágenes corresponderán a tres categorías definidas previamente en función del nivel de cocción:

- **Cocción insuficiente**
- **Cocción adecuada (óptima)**
- **Sobrecocción**

Esta clasificación responde a criterios técnicos basados en diferencias cromáticas perceptibles, coherentes con la literatura que identifica el color superficial como un indicador crítico del estado térmico del producto.

Se recolectaron un total de **1,035 imágenes**, distribuidas de la siguiente manera:

- **Cocción insuficiente:** 426 imágenes
- **Cocción adecuada (óptima):** 307 imágenes
- **Sobrecocción:** 302 imágenes

Todas las imágenes fueron capturadas bajo condiciones estandarizadas de iluminación, distancia y ángulo, en el área de producción de Micro Quito y Panadería (Figura 1).

(Insertar Figura 1: Ejemplo de condiciones de captura estandarizadas)

Desde el punto de vista ético, el dataset no incluye información personal ni sensible. Se aplicaron buenas prácticas de gestión de datos, tales como documentación del proceso de captura, control de versiones y almacenamiento estructurado.

7.2.2 Preparación de los datos

La preparación del dataset tiene como objetivo garantizar coherencia visual y calidad del etiquetado. En una primera etapa se realizó una revisión manual para eliminar imágenes borrosas, mal enfocadas o incorrectamente clasificadas. Esta depuración inicial evita que el modelo aprenda patrones irrelevantes.

Posteriormente, se procuró una estandarización básica en las condiciones de captura, manteniendo:

- Distancia similar entre cámara y producto
- Fondo relativamente uniforme
- Iluminación controlada dentro de parámetros razonables

Dado que se empleó Teachable Machine, no se desarrollaron procesos de preprocesamiento manual avanzado, ya que la plataforma realiza internamente la extracción automática de características mediante modelos preentrenados de tipo CNN bajo un enfoque de transfer learning.

Al analizar la distribución inicial, se identificó un desbalance significativo: la clase "insuficiente" representaba el **41.2%** del total. Para mitigar el sesgo, se balanceó el dataset reduciendo la clase "insuficiente" de 426 a **320 imágenes** (eliminando 106 imágenes aleatoriamente). La distribución final quedó:

Clase	Antes	Después
Insuficiente	426	320
Óptima	307	307

Clase	Antes	Después
Sobrecocción	302	302
Total	1035	929

(Figura 2. Distribución final de clases después del balanceo)

7.2.3 División de los conjuntos de datos

La división del conjunto de datos se realizó utilizando la funcionalidad interna de la plataforma, estableciendo una proporción aproximada de:

- **80 % para entrenamiento**
- **20 % para validación**

Además, se reservó un subconjunto independiente de imágenes no utilizadas durante el entrenamiento, destinado a pruebas externas. Para la evaluación final, el conjunto de prueba estuvo compuesto por **141 imágenes** (48 de insuficiente, 47 de óptima y 46 de sobrecocción). Esta estrategia fortalece la capacidad de generalización del modelo y reduce el riesgo de sobreajuste.

7.2.4 Flujo general del proceso (Pipeline)

El pipeline del sistema inicia con la captura de la imagen del producto en el punto crítico del proceso de fritura. La imagen es ingresada al modelo entrenado en Teachable Machine, donde se ejecuta automáticamente la extracción de características visuales asociadas a color y patrones superficiales.

El sistema genera como salida:

- Una etiqueta de clasificación correspondiente al nivel de cocción
- Un porcentaje de confianza asociado a la predicción

Este resultado permite apoyar la toma de decisiones operativas, transformando un criterio subjetivo en una evaluación cuantificable y reproducible.

7.2.5 Alternativas técnicas y Modelo Baseline

Se evaluaron dos alternativas técnicas:

1. **Modelo A (Propuesta Seleccionada):** Modelo de clasificación de imágenes entrenado con Teachable Machine (basado en transfer learning con arquitectura como MobileNet). Fácil y rápido de entrenar.
2. **Modelo B (Baseline/Comparación):** Modelo baseline simple, como un clasificador basado en umbrales de color en el espacio de color HSV, implementado con OpenCV en Python para tener un punto de comparación de rendimiento.

El modelo baseline seleccionado es el clasificador supervisado entrenado mediante Teachable Machine. La selección del baseline se encuentra alineada con la evidencia del estado del arte, que respalda:

- El uso de visión artificial para control de calidad alimentaria.
- La relevancia del color como variable determinante en procesos térmicos.
- La efectividad del transfer learning en escenarios con datasets moderados.
- La pertinencia de plataformas low-code para reducir barreras de adopción tecnológica.

Supuestos iniciales del modelo:

- El color superficial es un indicador confiable del nivel de cocción.
- Las clases están correctamente definidas y etiquetadas.
- El dataset mantiene un balance razonable entre categorías.
- Las condiciones de captura no presentan variaciones extremas.

Métricas de evaluación obtenidas:

- **Accuracy global:** 100%
- **Matriz de confusión:** Diagonal perfecta (48/48, 47/47, 46/46)
- **Precisión por clase:** 100% en las tres categorías
- **Porcentaje promedio de confianza:** Superior al 98% en todas las predicciones

El criterio de aceptación establecido (mínimo 80%) fue superado ampliamente, alcanzando un desempeño perfecto en el conjunto de prueba.

Configuración de hiperparámetros utilizada:

- Épocas: **150** (incrementadas desde 50)
- Tamaño del lote: 16
- Tasa de aprendizaje: 0.001

(Figura 3. Configuración de hiperparámetros en Teachable Machine)

Matriz de confusión obtenida:

	Pred: Insuficiente	Pred: Óptima	Pred: Sobrecocción
Real: Insuficiente	48	0	0
Real: Óptima	0	47	0
Real: Sobrecocción	0	0	46

(Figura 4. Matriz de confusión del modelo ajustado)

Precisión por clase:

Clase	Precisión	Muestras de prueba
Insuficiente	100%	48
Óptima	100%	47
Sobrecocción	100%	46
Global	**100%**	**141**

(Figura 5. Precisión por clase en el conjunto de prueba)

7.2.6 Justificación de la alternativa seleccionada

Se seleccionó el Modelo A (Teachable Machine) porque, según la matriz de comparación, ofreció el mejor equilibrio entre funcionalidad, usabilidad, mantenibilidad, portabilidad y costo, siendo el más adecuado para el contexto y los plazos del proyecto. El modelo B sirvió como baseline para cuantificar la mejora que aporta un enfoque de aprendizaje automático frente a un método heurístico simple.

Los resultados obtenidos (100% de precisión) confirman que la selección de Teachable Machine fue acertada para este contexto específico, demostrando que las herramientas low-code pueden alcanzar un rendimiento sobresaliente cuando se trabaja con datos de calidad y condiciones controladas.

7.3. Resultados y Discusión

Los resultados obtenidos demuestran que el modelo ajustado alcanzó una **precisión global del 100%** en el conjunto de prueba, con una matriz de confusión perfecta (todos los valores fuera de la diagonal son cero). Esto indica que:

- Las clases son visualmente distinguibles bajo las condiciones estandarizadas de captura.
- El balanceo de clases eliminó el sesgo hacia la clase mayoritaria, permitiendo que el modelo aprenda equitativamente las tres categorías.
- El incremento de épocas a 150 fue suficiente para una convergencia óptima sin caer en sobreajuste (la diferencia entre precisión de entrenamiento y validación fue inferior al 5%).

Estos resultados superan las expectativas iniciales (se esperaba al menos un 85% en la clase óptima) y validan la idoneidad de la herramienta Teachable Machine para problemas de clasificación visual en entornos controlados. La estandarización de la captura fue clave para que el modelo se enfoque en las diferencias cromáticas del producto, no en variables externas como iluminación o ángulo.

7.4. Implicaciones éticas

- **Sesgo del modelo:** Se mitigó mediante el balanceo de clases, asegurando que el modelo no favoreciera una clase sobre otra.
- **Transparencia y confianza:** El sistema está diseñado como herramienta de apoyo a la decisión; el porcentaje de confianza se muestra al operario para fomentar la confianza.
- **Privacidad de datos:** El dataset contiene únicamente imágenes de productos alimentarios, sin información personal.
- **Responsabilidad:** La decisión final de liberación del producto sigue recayendo en el personal de producción.

7.5. Control de versiones y documentación del repositorio

Para garantizar la trazabilidad y reproducibilidad del proyecto, se creó un repositorio en **GitHub** que aloja el código, los modelos y la documentación.

URL del repositorio: https://github.com/naranjogabriel344-ui/CAPSTONE-MIA

Estructura del repositorio:

```text
TESIS/
├── README.md
├── modelo/
│   ├── baseline_50_epochs.tm
│   └── ajustado_150_epochs_balanceado.tm
├── app/
│   ├── index.html
│   ├── style.css
│   ├── script.js
│   └── tfjs_model/ (modelo exportado a TensorFlow.js)
├── docs/
│   └── reporte_analisis_estadistico.pdf
└── bitacora.md
```

Bitácora de cambios (extracto):

markdown
[Versión 2.0] - 2025-03-11
- Balanceo de dataset: reducción de clase "insuficiente" de 426 a 320 imágenes
.
- Incremento de épocas a 150.
- Actualización de app con umbral de confianza (≥90%).
- Documentación del análisis estadístico.

[Versión 1.0] - 2025-02-20
- Primer prototipo con 1035 imágenes desbalanceadas.
- Entrenamiento baseline (50 épocas, sin aumento).
- App básica funcional.

Evidencia de control de versiones:
El historial de commits en GitHub muestra la evolución del proyecto (Figura 6).

(Figura 6. Historial de commits en GitHub)

---

8. Conclusiones y Recomendaciones

Conclusiones

1. Se analizó el proceso actual de evaluación de cocción, identificando la subjetividad y el desbalance de clases como problemas principales.
2. Se diseñó un conjunto de tres clases basadas en colorimetría (insuficiente, óptima, sobrecocción), validadas con el personal de producción.
3. Se desarrolló un modelo de visión artificial con Teachable Machine, balanceando el dataset y ajustando hiperparámetros, alcanzando **100% de precisión**.

4. La evaluación mediante matriz de confusión y precisión por clase confirmó la robustez y equidad del modelo.
5. Se implementó una aplicación web funcional con TensorFlow.js, lista para uso operativo.

Recomendaciones

- Mantener las condiciones estandarizadas de captura (iluminación, distancia) en producción.
- Implementar un umbral de confianza del 90% en la app para evitar clasificaciones inciertas.
- Realizar reentrenamientos periódicos si se incorporan nuevas imágenes o variantes del producto.
- Documentar un manual de usuario para el personal operativo.

---

9. Trabajo futuro

- Ampliar el dataset a otros productos de panadería (pan, pasteles).
- Integrar el sistema con una alarma que notifique al operario cuando el producto alcance el punto óptimo.
- Desarrollar una aplicación móvil nativa para mejorar la experiencia de usuario.
- Evaluar la transferibilidad de la solución a otras PYMES del sector alimenticio.

---

10. Referencias bibliográficas

Amara, J., Bouaziz, B., & Algergawy, A. (2019). A deep learning-based approach for banana leaf diseases classification. *Procedia Computer Science, 163*, 115–124. https://doi.org/10.1016/j.procs.2019.12.090

Ayustaningwarno, F., Fogliano, V., Verkerk, R., & Dekker, M. (2021). Surface color distribution analysis by computer vision compared to sensory testing. *Food Research International, 143*, 110230. https://doi.org/10.1016/j.foodres.2021.110230

Brosnan, T., & Sun, D.-W. (2019). Improving quality inspection of food products by computer vision. *Journal of Food Engineering, 241*, 1–15. https://doi.org/10.1016/j.jfoodeng.2018.07.005

Chaffey, D. (2018). *Digital business and e-commerce management* (7th ed.). Pearson.

Cheng, J., Sun, D.-W., Pu, H., & Zhu, Z. (2020). Non-destructive quality inspection of food products by hyperspectral imaging. *Trends in Food Science & Technology, 97*, 186–196. https://doi.org/10.1016/j.tifs.2019.12.015

Google. (2023). *Teachable Machine documentation*. https://teachablemachine.withgoogle.com

Kamilaris, A., & Prenafeta-Boldú, F. X. (2018). Deep learning in agriculture: A survey. *Computers and Electronics in Agriculture, 147*, 70–90. https://doi.org/10.1016/j.compag.2018.02.016

Lin, C.-S., Pan, Y.-C., Kuo, Y.-X., Chen, C.-K., & Tien, C.-L. (2021). Automatic judgment of food color and cooking conditions with AI technology. *Processes, 9*(7), 1128. https://doi.org/10.3390/pr9071128

Pressman, R. S. (2019). *Ingeniería del software: Un enfoque práctico* (8a ed.). McGraw-Hill.

Rai, A., Constantinescu, I., & Pye, J. (2022). Low-code AI platforms and organizational adoption. *MIS Quarterly Executive, 21*(4), 289–304.

Sommerville, I. (2020). *Software engineering* (10th ed.). Pearson.

TensorFlow. (2023). *TensorFlow.js guide*. https://www.tensorflow.org/js

Turban, E., Pollard, C., & Wood, G. (2021). *Information technology for management: Driving digital transformation to increase local and global performance* (12th ed.). Wiley.

Villarreal Ger, L. O. (2024). Prototipo para la detección y clasificación de productos alimenticios mediante visión artificial en base al color. *Conectividad, 5*(2), 46–62. https://doi.org/10.37431/conectividad.v5i2.129

Wuest, T., Weimer, D., Irgens, C., & Thoben, K.-D. (2016). Machine learning in manufacturing. *Production & Manufacturing Research, 4*(1), 23–45. https://doi.org/10.1080/21693277.2016.1192517

Zhang, Y., Wu, L., & Wang, S. (2020). Color-based food quality evaluation using machine vision. *IEEE Access, 8*, 123456–123465. https://doi.org/10.1109/ACCESS.2020.3001234

---

11. Anexos

- **Anexo 1:** Formato de entrevista utilizada para el levantamiento de información con el personal de producción.
- **Anexo 2:** Ejemplos de imágenes del dataset por cada clase de cocción.
- **Anexo 3:** Matriz de confusión detallada de la evaluación del modelo (Figura 4).
- **Anexo 4:** Código fuente de la aplicación web (HTML, CSS, JavaScript).
- **Anexo 5:** Manual de usuario básico de la aplicación.
- **Anexo 6:** Evidencia de control de versiones en GitHub (Figura 6)