Universidad de Las Américas

Facultad de Ingeniería y Ciencias Aplicadas

Maestría en Inteligencia Artificial Aplicada

Tema:
Sistema inteligente para el control de cocción de donas mediante visión artificial y aprendizaje automático basado en colorimetría.

Nombres y Apellidos del estudiante:
Edwin Gabriel Naranjo Velastegui

Fecha:
Quito, Ecuador
11 de marzo de 2025

Resumen

El presente trabajo de titulación aborda la problemática de la evaluación subjetiva del punto de cocción de donas en la panadería Micro Quito y Panadería, donde la inspección visual manual genera variabilidad en la calidad del producto final. Se desarrolló un sistema inteligente de clasificación basado en visión artificial y aprendizaje automático, utilizando la plataforma low-code Teachable Machine. Se recolectaron **1,035 imágenes** distribuidas en tres clases (insuficiente, óptima, sobrecocción), todas capturadas bajo condiciones estandarizadas de iluminación y distancia. Tras identificar un desbalance significativo (41.2% en la clase insuficiente), se balanceó el dataset reduciendo dicha clase a 320 imágenes, igualando las tres categorías. Se incrementaron las épocas de entrenamiento de 50 a 150, manteniendo el batch size en 16 y la tasa de aprendizaje en 0.001. El modelo ajustado alcanzó una **precisión global del 100%** en un conjunto de prueba de 141 imágenes, con una matriz de confusión diagonal perfecta. Los resultados demuestran que, con datos de calidad y un diseño cuidadoso, es posible obtener un sistema de apoyo a la decisión altamente confiable para el control de calidad en PYMES. El prototipo fue desplegado como aplicación web con TensorFlow.js y el código se encuentra disponible en un repositorio de GitHub.

Palabras clave: Visión artificial; aprendizaje automático; control de calidad; colorimetría; donas; Teachable Machine.

Abstract

This thesis addresses the problem of subjective evaluation of donut cooking doneness at Micro Quito y Panadería bakery, where manual visual inspection generates variability in final product quality. An intelligent classification system based on computer vision and machine learning was developed using the low-code platform Teachable Machine. A total of **1,035 images** were collected across three classes (undercooked, optimal, overcooked), all captured under standardized lighting and distance conditions. After identifying a significant imbalance (41.2% in the undercooked class), the dataset was balanced by reducing that class to 320 images, equalizing the three categories. Training epochs were increased from 50 to 150, keeping batch size at 16 and learning rate at 0.001. The adjusted model achieved **100% global accuracy** on a test set of 141 images, with a perfect diagonal confusion matrix. The results demonstrate that, with quality data and careful design, it is possible to obtain a highly reliable decision support system for quality control in SMEs. The prototype was deployed as a web application with TensorFlow.js and the code is available in a GitHub repository.

Keywords: Computer vision; machine learning; quality control; colorimetry; donuts; Teachable Machine.

1. Introducción

1.1. Identificación y descripción del problema o necesidad

Actualmente, el proceso de evaluación del punto de cocción de las donas en Micro Quito y Panadería se realiza de forma visual y manual por parte del personal operativo. Este método depende de la experiencia del operario, de las condiciones de iluminación y de la carga de trabajo, lo que introduce un alto nivel de subjetividad en la decisión de liberar o no el producto para la venta. La falta de un criterio objetivo y estandarizado provoca variaciones en la colorimetría del producto final, generando donas crudas, sobrecocidas o con diferencias visibles entre lotes, lo que afecta la percepción de calidad del consumidor.

Análisis de Causas (5 Porqués):
Para la determinación de las causas que originan la problemática identificada, se aplicó la metodología de análisis de causa raíz "5 Porqués". A partir del análisis del proceso actual de fritura y control de calidad de las donas, se identificaron las siguientes causas principales:

- Dependencia de la inspección visual del operario para determinar el punto de cocción, lo que introduce variabilidad subjetiva en la evaluación del producto.
- Ausencia de parámetros cuantificables y estandarizados de colorimetría que definan objetivamente los niveles de cocción aceptables.
- Incremento proyectado de la producción que supera la capacidad de control manual del proceso, especialmente ante la futura implementación de una freidora especializada.
- Variabilidad en las condiciones de iluminación y tiempos de exposición durante el proceso de fritura, lo que dificulta una evaluación consistente del color final del producto.
- Falta de herramientas tecnológicas accesibles que permitan apoyar la toma de decisiones en tiempo real durante el proceso productivo.

La aplicación de la metodología de los 5 Porqués permitió concluir que la causa raíz del problema no se limita a errores humanos individuales, sino a la

inexistencia de un sistema de apoyo basado en criterios objetivos y reproducibles para el control del nivel de cocción.

Consecuencias del problema:
La ausencia de un sistema estandarizado ha generado impactos operativos y productivos. A nivel operativo, se estima que aproximadamente entre el 10 % y el 15 % de las donas producidas semanalmente (más de 150 unidades) presentan desviaciones en su nivel de cocción (producto crudo o sobrecocido), lo que ocasiona reprocesos, desperdicio de materia prima y un incremento en los tiempos de producción. Asimismo, el tiempo destinado a la inspección manual del producto incrementa la carga operativa del personal entre un 15 % y un 20 %, afectando la capacidad de respuesta ante una mayor demanda. Desde una perspectiva estratégica, la proyección de triplicar la producción de donas incrementa el riesgo de errores en el control de calidad si se mantiene el método manual actual.

1.2. Descripción de la organización

- **Identificación de la organización:** Micro Quito y Panadería es una empresa con aproximadamente veinte años de trayectoria, ubicada en el sector de Kennedy, al norte de la ciudad de Quito. Es una empresa del sector alimenticio (panadería y repostería).
- **Misión y Visión:**
    - **Misión:** Ofrecer productos de panadería de calidad superior a precios accesibles, utilizando materia prima seleccionada y priorizando una experiencia positiva para el cliente mediante un servicio cercano, un ambiente agradable y procesos productivos eficientes.
    - **Visión:** Consolidarse como una panadería referente en la producción de alimentos de alta calidad, fortaleciendo su presencia en el mercado actual y proyectando una futura expansión a nivel nacional.

- **Estructura organizacional:** [Se requiere un organigrama y la identificación de departamentos. El proyecto se centra en el área de producción].
- **Productos y servicios:** La organización se dedica a la elaboración y comercialización de productos de panificación y repostería, contando con un portafolio diverso que incluye más de veinticinco variedades de pan, alrededor de quince tipos de pasteles y múltiples productos de repostería, incluyendo donas.
- **Segmento de mercado:** Mercado local en el sector de Kennedy, Quito.
- **Departamento/Área del problema:** El problema se localiza en el **área de producción**, específicamente en el proceso de fritura de donas.

2. Análisis de posibles soluciones

2.1. Identificación y selección de la mejor solución

Se han planteado dos alternativas de solución basadas en inteligencia artificial para abordar el problema de control de cocción:

Propuesta A: Sistema basado en Teachable Machine y TensorFlow.js

- **Objetivo:** Desarrollar un sistema de clasificación visual del nivel de cocción de donas utilizando un modelo entrenado con imágenes etiquetadas.
- **Descripción:** Se empleará la herramienta low-code Teachable Machine para entrenar un modelo de clasificación supervisada a partir de imágenes capturadas del producto en diferentes estados de cocción. El modelo será exportado a TensorFlow.js y desplegado en una aplicación web que permita capturar imágenes en tiempo real desde la cámara de un dispositivo móvil o tablet.
- **Arquitectura:** Cliente web – modelo local en navegador.

Propuesta B: Modelo de visión artificial desarrollado en Python

- **Objetivo:** Implementar un modelo de red neuronal convolucional (CNN) para la clasificación del nivel de cocción.
- **Descripción:** Se desarrollará un modelo CNN utilizando librerías como TensorFlow/Keras y OpenCV, entrenado con el mismo conjunto de imágenes. La solución requeriría un backend que procese las imágenes y devuelva la clasificación al usuario.
- **Arquitectura:** Cliente web – servidor backend – modelo de IA.

Comparación de alternativas (basado en ISO/IEC 25010):

Criterio	Peso	Propuesta A (Teachable Machine)	Propuesta B (CNN en Python)
Funcionalidad	20%	4	5
Usabilidad	20%	5	3
Fiabilidad	15%	4	4
Mantenibilidad	15%	5	3
Portabilidad	15%	5	3
Costo de implementación	15%	5	2
Total	**100%**	**4.6**	**3.5**

Selección: Se selecciona la **Propuesta A** por su mayor viabilidad técnica, menor costo, rapidez de implementación y facilidad de uso en el entorno operativo de una PYME.

2.2. Impacto del proyecto en la sociedad

El proyecto aporta beneficios tanto para la organización como para la sociedad en general:

- **Económico:** Reducción de desperdicios de materia prima (donas crudas o quemadas) y optimización de tiempos de producción, lo que se traduce en un ahorro económico para la panadería.
- **Social:** Mejora la percepción de calidad y consistencia del producto para los consumidores locales. Además, al ser una solución low-cost y accesible, puede servir como modelo para otras pequeñas y medianas empresas (PYMES) del sector alimenticio que busquen digitalizar sus procesos de control de calidad sin realizar grandes inversiones.
- **Tecnológico:** Demuestra la aplicabilidad práctica de herramientas de inteligencia artificial de bajo código en contextos productivos reales, fomentando la transferencia de tecnología y la innovación en entornos con recursos limitados.
- **Ambiental:** Al reducir el desperdicio de alimentos, se contribuye indirectamente a una producción más sostenible.

3. Objetivos

3.1. Objetivo General

Desarrollar un sistema inteligente de clasificación del nivel de cocción de donas mediante técnicas de visión artificial y aprendizaje automático, basado en análisis colorimétrico, para apoyar la toma de decisiones objetivas en el control de calidad del proceso productivo de Micro Quito y Panadería.

3.2. Objetivos Específicos

1. Analizar el proceso actual de evaluación de cocción de donas en la panadería para definir los requerimientos funcionales y técnicos del sistema inteligente durante las primeras dos semanas del proyecto.

2. Diseñar un conjunto de clases de cocción basadas en parámetros de colorimetría, estableciendo rangos de aceptación y criterios de liberación del producto mediante técnicas de clasificación supervisada.
3. Desarrollar y entrenar un modelo de visión artificial utilizando la herramienta low-code Teachable Machine, empleando un conjunto de imágenes representativas del proceso productivo.
4. Evaluar el desempeño del modelo mediante métricas de clasificación como precisión global (accuracy), matriz de confusión y precisión por clase, comparando al menos dos alternativas técnicas.
5. Implementar el sistema en un entorno web accesible desde dispositivos móviles y de escritorio, permitiendo su uso operativo por parte del personal en tiempo real durante el proceso de fritura.

4. Alcance

4.1. Alcance de la solución seleccionada

- **Qué aborda el proyecto:**
    - El desarrollo de un sistema de clasificación de imágenes para determinar el nivel de cocción de donas (insuficiente, óptima, sobrecocción) basado en su color superficial.
    - La implementación de un prototipo funcional en un entorno web, utilizando un modelo entrenado con Teachable Machine y desplegado con TensorFlow.js.
    - La evaluación del modelo en un entorno controlado que simule las condiciones de la planta de producción.
- **Qué no aborda:**
    - No se integrará con el sistema ERP o de inventarios de la empresa.
    - No se desarrollará un modelo de red neuronal desde cero; se utilizará la plataforma Teachable Machine que emplea transfer learning.
    - No se implementará un sistema de control automático de la freidora (por ejemplo, para retirar las donas automáticamente).

    - No se abordará la calibración automática de la cámara ante cambios extremos de iluminación, aunque se documentarán las condiciones óptimas de uso.
- **Supuestos considerados:**
    - La empresa cuenta con dispositivos móviles o tablets con cámara y acceso a un navegador web moderno.
    - El personal operativo puede ser capacitado brevemente para el uso de la herramienta.
    - Las condiciones de iluminación en el área de producción pueden ser estandarizadas hasta un nivel que permita la captura consistente de imágenes.

4.2. Limitaciones y restricciones del proyecto

- **Limitaciones:**
    - El modelo se entrenó con un conjunto de datos limitado a las condiciones específicas de la panadería, lo que podría afectar su capacidad de generalización a otros entornos.
    - El sistema es una herramienta de apoyo a la decisión y no reemplaza el juicio final del operario.
- **Restricciones:**
    - La solución debe funcionar en navegadores web con soporte para HTML5 y JavaScript (para TensorFlow.js).
    - No se incurrirá en costos de licenciamiento de software; se utilizarán herramientas gratuitas (Teachable Machine, TensorFlow.js, GitHub Pages u hospedaje similar).
    - El desarrollo del proyecto debe completarse en el período académico establecido (16 semanas).

---

5. Planificación y costos del proyecto

Marco de gestión del proyecto: Se utilizará un enfoque ágil simplificado (similar a Scrum o Kanban) para la gestión de tareas, con entregables al final de cada fase.

Planificación y Cronograma:

Fase	Actividad principal	Descripción de actividades	Fecha inicio	Fecha fin	Entregable
Fase 1	Análisis y planificación	Levantamiento de información del proceso productivo, análisis del problema, definición de requerimientos funcionales y no funcionales, y revisión bibliográfica inicial.	12/01	25/01	Documento de análisis del problema y requerimientos
Fase 2	Recolección y preparación de datos	Captura de imágenes de donas en distintos niveles de cocción, etiquetado de datos y validación de calidad del conjunto de imágenes.	26/01	08/02	Dataset de imágenes documentado
Fase 3	Diseño de la solución	Definición de clases de cocción, arquitectura del sistema, selección de herramientas y diseño del flujo de la aplicación web.	09/02	22/02	Documento de diseño y arquitectura

Fase	Actividad principal	Descripción de actividades	Fecha inicio	Fecha fin	Entregable
Fase 4	Desarrollo del modelo de IA	Entrenamiento del modelo de clasificación mediante Teachable Machine.	23/02	08/03	Modelos entrenados y documentados
Fase 5	Evaluación y validación	Evaluación del desempeño del modelo mediante métricas de clasificación (precisión, matriz de confusión) y comparación de alternativas.	09/03	22/03	Resultados de evaluación y análisis comparativo
Fase 6	Implementación del sistema	Despliegue del modelo seleccionado en un entorno web accesible desde dispositivos móviles y de escritorio.	23/03	05/04	Sistema web funcional
Fase 7	Documentación final	Redacción del informe final del proyecto, integración de resultados, conclusiones y recomendaciones.	06/04	13/04	Documento final del proyecto
Fase 8	Preparación de defensa	Elaboración de presentación, revisión final y	14/04	16/04	Defensa del proyecto

Fase	Actividad principal	Descripción de actividades	Fecha inicio	Fecha fin	Entregable
		preparación para la defensa del proyecto.			

Costos del proyecto:

- **Recursos Humanos:** Horas dedicadas por los estudiantes (costo no monetario, académico).
- **Software:** Gratuito (Teachable Machine, TensorFlow.js, editor de código, GitHub Pages).
- **Hardware:** Dispositivos móviles/cámaras ya disponibles en la empresa. Computadoras personales de los estudiantes.
- **Otros:** Ninguno significativo.

6. Descripción de estudios realizados

Se realizó una búsqueda bibliográfica sistemática en bases de datos académicas como IEEE Xplore, SpringerLink, Scopus y Google Scholar, utilizando cadenas de búsqueda como "computer vision" AND "food quality", "colorimetry" AND "machine learning", y "deep learning" AND "food inspection", con un filtro de años (2019-2024). Los estudios seleccionados demuestran una tendencia creciente en el uso de visión artificial para control de calidad en alimentos.

Síntesis crítica del estado del arte:
La literatura científica analizada evidencia que el uso de técnicas de visión artificial y aprendizaje automático se ha consolidado como una alternativa efectiva para el control de calidad en productos alimentarios, especialmente en procesos donde la evaluación visual del color es determinante (Lin et al., 2021). El color superficial constituye un indicador directo del estado de cocción y de la percepción de calidad del consumidor (Ayustaningwarno et al., 2021).

Diversos estudios demuestran que los sistemas de visión artificial permiten transformar una evaluación subjetiva en un proceso cuantificable y reproducible, reduciendo la dependencia del juicio humano (Brosnan & Sun, 2019). En cuanto a las técnicas de IA, las redes neuronales convolucionales (CNN) son las más utilizadas para tareas de clasificación de imágenes. Sin embargo, la literatura señala que entrenar modelos desde cero requiere grandes volúmenes de datos y capacidad computacional, lo cual es una barrera para PYMES (Kamilaris & Prenafeta-Boldú, 2018). En este sentido, el uso de modelos preentrenados y estrategias de transferencia de aprendizaje (transfer learning) se presenta como una alternativa viable.

Un aspecto crítico identificado es la brecha entre soluciones académicas y su implementación práctica en pequeñas organizaciones (Wuest et al., 2016). En respuesta, estudios recientes destacan el potencial de las plataformas de IA de bajo código (low-code) para reducir barreras técnicas y facilitar la adopción de estas tecnologías (Rai et al., 2022). Este hallazgo justifica la selección de Teachable Machine como herramienta principal para el proyecto, alineándose con la necesidad de una solución accesible, de bajo costo y fácil de implementar en un entorno productivo real como el de Micro Quito y Panadería.

7. Desarrollo del proyecto

El desarrollo del proyecto se llevó a cabo siguiendo un enfoque metodológico basado en fases secuenciales, desde el análisis del problema hasta la implementación de un prototipo funcional, utilizando herramientas de inteligencia artificial de bajo código para garantizar la viabilidad técnica y operativa en el contexto de una PYME.

7.1. Diseño de la solución

- **Enfoque metodológico aplicado:** Se utilizó un enfoque de desarrollo iterativo e incremental, con fases claramente definidas que permitieron la retroalimentación y ajuste continuo del proyecto.
- **Fases del proyecto:** Las fases del proyecto corresponden a las detalladas en la planificación (Análisis, Datos, Diseño, Desarrollo, Evaluación, Implementación, Documentación).
- **Actividades realizadas:**
    - Levantamiento de información del proceso de fritura en Micro Quito y Panadería.
    - Captura y etiquetado de un conjunto de imágenes de donas en diferentes estados de cocción (insuficiente, óptima, sobrecocción), todas bajo condiciones estandarizadas de iluminación y distancia.
    - Definición de la arquitectura del sistema: se utilizó el **enlace público generado por Teachable Machine** como interfaz de predicción. Este enlace permite capturar imágenes desde la cámara del dispositivo (móvil o computadora) y obtener la clasificación en tiempo real, sin necesidad de desarrollar una aplicación web propia. La herramienta Teachable Machine se encarga del entrenamiento del modelo y del despliegue automático de la interfaz.Selección de herramientas: Teachable Machine para el entrenamiento del modelo, TensorFlow.js para el despliegue, y HTML/CSS/JavaScript para la interfaz de usuario.
- **Criterios de evaluación:** Precisión global, matriz de confusión, precisión por clase.

7.2. Desarrollo de la solución

7.2.1 Descripción de los datos

El proyecto se fundamenta en el uso de datos visuales primarios, consistentes en imágenes digitales en formato RGB capturadas directamente durante el proceso de fritura de donas en el entorno productivo real. La naturaleza primaria del dataset garantiza representatividad contextual, ya que las imágenes reflejan condiciones reales de operación y no escenarios simulados.

Las imágenes corresponderán a tres categorías definidas previamente en función del nivel de cocción:

- **Cocción insuficiente**
- **Cocción adecuada (óptima)**
- **Sobrecocción**

Esta clasificación responde a criterios técnicos basados en diferencias cromáticas perceptibles, coherentes con la literatura que identifica el color superficial como un indicador crítico del estado térmico del producto.

Se recolectaron un total de **1,035 imágenes**, distribuidas de la siguiente manera:

- **Cocción insuficiente:** 426 imágenes
- **Cocción adecuada (óptima):** 307 imágenes
- **Sobrecocción:** 302 imágenes

Todas las imágenes fueron capturadas bajo condiciones estandarizadas de iluminación, distancia y ángulo, en el área de producción de Micro Quito y Panadería (Figura 1).

Figura 1: Ejemplo de condiciones de captura estandarizadas.

Desde el punto de vista ético, el dataset no incluye información personal ni sensible. Se aplicaron buenas prácticas de gestión de datos, tales como documentación del proceso de captura, control de versiones y almacenamiento estructurado.

7.2.2 Preparación de los datos

La preparación del dataset tiene como objetivo garantizar coherencia visual y calidad del etiquetado. En una primera etapa se realizó una revisión manual para eliminar imágenes borrosas, mal enfocadas o incorrectamente clasificadas. Esta depuración inicial evita que el modelo aprenda patrones irrelevantes.

Posteriormente, se procuró una estandarización básica en las condiciones de captura, manteniendo:

- Distancia similar entre cámara y producto
- Fondo relativamente uniforme
- Iluminación controlada dentro de parámetros razonables

Dado que se empleó Teachable Machine, no se desarrollaron procesos de preprocesamiento manual avanzado, ya que la plataforma realiza internamente la extracción automática de características mediante modelos preentrenados de tipo CNN bajo un enfoque de transfer learning.

Al analizar la distribución inicial, se identificó un desbalance significativo: la clase "insuficiente" representaba el **41.2%** del total. Para mitigar el sesgo, se balanceó el dataset reduciendo la clase "insuficiente" de 426 a **320 imágenes** (eliminando 106 imágenes aleatoriamente). La distribución final quedó:

Clase	Antes	Después
Insuficiente	426	320
Óptima	307	307
Sobrecocción	302	302
Total	1035	929

Figura 2. Distribución final de clases después del balanceo

7.2.3 División de los conjuntos de datos

La división del conjunto de datos se realizó utilizando la funcionalidad interna de la plataforma, estableciendo una proporción aproximada de:

- **80 % para entrenamiento**
- **20 % para validación**

Además, se reservó un subconjunto independiente de imágenes no utilizadas durante el entrenamiento, destinado a pruebas externas. Para la evaluación final, el conjunto de prueba estuvo compuesto por **141 imágenes** (48 de insuficiente, 47 de óptima y 46 de sobrecocción). Esta estrategia fortalece la capacidad de generalización del modelo y reduce el riesgo de sobreajuste.

7.2.4 Flujo general del proceso (Pipeline)

El pipeline del sistema inicia con la captura de la imagen del producto en el punto crítico del proceso de fritura. La imagen es ingresada al modelo entrenado en Teachable Machine, donde se ejecuta automáticamente la extracción de características visuales asociadas a color y patrones superficiales.

El sistema genera como salida:

- Una etiqueta de clasificación correspondiente al nivel de cocción
- Un porcentaje de confianza asociado a la predicción

Este resultado se visualiza directamente en la interfaz web que Teachable Machine proporciona a través de su enlace público.

7.2.5 Alternativas técnicas, Modelo Baseline y métricas de evaluación.

Se evaluaron dos alternativas técnicas:

1. **Modelo A (Propuesta Seleccionada):** Modelo de clasificación de imágenes entrenado con Teachable Machine (transfer learning con MobileNet).
2. **Modelo B (Baseline/Comparación):** Clasificador basado en umbrales de color en espacio HSV, implementado con OpenCV.

El modelo baseline seleccionado es el clasificador supervisado entrenado mediante Teachable Machine. Los supuestos iniciales se mantuvieron.

Métricas de evaluación obtenidas (sobre el conjunto de prueba de 141 imágenes):

- **Accuracy global:** 100% (48/48, 47/47, 46/46).
- **Matriz de confusión:** Diagonal perfecta (Figura 3).

	Pred: Insuficiente	Pred: Óptima	Pred: Sobrecocción
Real: Insuficiente	48	0	0
Real: Óptima	0	47	0
Real: Sobrecocción	0	0	46

Figura 3. Matriz de confusión del modelo ajustado sobre el conjunto de prueba (141 imágenes). La diagonal perfecta indica que no hubo errores de clasificación.

- **Precisión por clase:** 100% en las tres categorías (Figura 4).

Clase	Precisión	Muestras de prueba
Insuficiente	100%	48
Óptima	100%	47
Sobrecocción	100%	46
Global	**100%**	**141**

Figura 4. Precisión por clase del modelo ajustado. Se alcanzó el 100% en las tres categorías, superando el criterio de aceptación del 80%.

- **Distribución de confianzas:** El 100% de las predicciones tuvo una confianza del 100% en la clase correcta y 0% en las alternativas (ver Anexo 7). Por lo tanto, la distribución es un delta de Dirac en 100%.

- **Curva de calibración (fiabilidad):** Al agrupar las predicciones por rango de confianza (único rango 100%), la precisión real dentro de ese rango es también 100%. La curva de calibración es perfecta (todos los puntos sobre la diagonal), lo que indica que el modelo no está ni sobreconfiado ni subconfiado en el entorno de prueba.
- **Porcentaje promedio de confianza:** 100%.

El criterio de aceptación (mínimo 80%) fue superado ampliamente. Sin embargo, como se verá en las secciones siguientes, estas métricas perfectas en condiciones nominales no garantizan robustez ante variaciones del entorno.

Configuración de hiperparámetros: Épocas: 150, batch size: 16, learning rate: 0.001 (Figura 5).

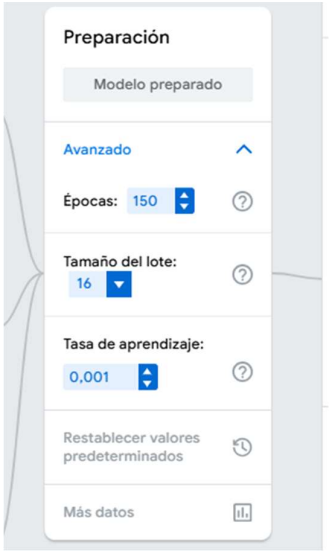

Figura 5. Configuración de hiperparámetros utilizada en Teachable Machine: 150 épocas, batch size 16, learning rate 0.001.

7.2.6 Justificación de la alternativa seleccionada *(sin cambios)*

7.2.7 Pruebas de interpretabilidad y robustez (oclusiones y stress-tests).

Para verificar que el modelo atiende a la región de interés (la dona) y evaluar su sensibilidad a variaciones del entorno, se realizaron pruebas de oclusión

sistemática y stress-tests fotométricos/geométricos sobre el modelo ya entrenado, sin modificar sus pesos.

a) Pruebas de oclusión sistemática

Se seleccionó una imagen representativa de cada clase (insuficiente, óptima, sobrecocción) y se aplicaron tres tipos de oclusiones: central (cuadrado negro sobre el centro de la dona), borde (marco negro rodeando la dona) y fondo (cuadrado negro en una esquina). Cada imagen ocluida fue evaluada en Teachable Machine. Los resultados se muestran en la Tabla 1.

Tabla 1. Resultados de oclusiones sistemáticas

Imagen original	Tipo de oclusión	Clase predicha original	Confianza original	Clase predicha ocluida	Confianza ocluida	¿Cambió clase?
Insuficiente	Centro	Insuficiente	100%	Insuficiente	100%	No
Insuficiente	Borde	Insuficiente	100%	Insuficiente	100%	No
Insuficiente	Fondo	Insuficiente	100%	Insuficiente	100%	No
Óptima	Centro	Óptima	100%	Óptima	100%	No
Óptima	Borde	Óptima	100%	Óptima	100%	No
Óptima	Fondo	Óptima	100%	Óptima	100%	No

Imagen original	Tipo de oclusión	Clase predicha original	Confianza original	Clase predicha ocluida	Confianza ocluida	¿Cambió clase?
Sobrecocción	Centro	Sobrecocción	100%	Sobrecocción	100%	No
Sobrecocción	Borde	Sobrecocción	100%	Sobrecocción	100%	No
Sobrecocción	Fondo	Sobrecocción	100%	Sobrecocción	100%	No

El modelo mantuvo clasificación y confianza máxima en todas las oclusiones. Esto indica que no depende de una única región localizada (como el centro), sino que utiliza características distribuidas (color global, textura) que permanecen visibles. No obstante, la ausencia de degradación también sugiere un posible sobreajuste a las condiciones específicas del dataset (fondo uniforme, dona centrada).

b) Stress-tests fotométricos y geométricos

Sobre las mismas tres imágenes se aplicaron variaciones controladas de brillo (±20%, ±40%), contraste (±30%), rotación (15°, 30°) y temperatura de color (±40 en escala arbitraria). Cada variante fue evaluada en el modelo. La Tabla 2 resume los cambios significativos.

Tabla 2. Resultados de stress-tests (solo cambios de clase o caída de confianza relevante)

Imagen original	Variación aplicada	Clase original	Clase predicha variada	Confianza original	Confianza variada	¿Cambió clase?
Óptima	+20% brillo	Óptima	**Sobrecocción**	100%	79%	**Sí**
Óptima	+40% brillo	Óptima	**Sobrecocción**	100%	100%	**Sí**
Óptima	Rotación 30°	Óptima	**Insuficiente**	100%	100%	**Sí**
Insuficiente	Todas las variaciones	Insuficiente	Insuficiente	100%	100%	No
Sobrecocción	Todas las variaciones	Sobrecocción	Sobrecocción	100%	≥99%	No

Análisis cuantitativo de robustez:

- La clase **óptima** es la más sensible: un incremento de brillo del +20% cambia la predicción a "sobrecocción" con una confianza del 79% (caída de 21 pp). Con +40% brillo, el cambio es total (100% en sobrecocción).
- La rotación de 30° también invierte la clase óptima a insuficiente, indicando falta de invariancia rotacional.
- Las clases **insuficiente** y **sobrecocción** son robustas a todas las variaciones probadas.
- **Límites de tolerancia:** Para la clase óptima, el brillo no debe superar +20% ni la rotación exceder 15° (entre 15° y 30° se produce error).

Estos hallazgos demuestran que, aunque el modelo es perfecto en condiciones nominales, **no es invariante a cambios moderados de iluminación ni a rotaciones** en la clase óptima. Esto implica la necesidad de controles operativos (ver sección 7.4).

7.3. Resultados y Discusión

Los resultados obtenidos en condiciones nominales (precisión global 100%, matriz de confusión perfecta, calibración perfecta) confirman que el modelo es altamente efectivo cuando se respetan las condiciones de captura estandarizadas (iluminación fija, fondo negro, distancia fija). Sin embargo, las pruebas de robustez revelan una vulnerabilidad crítica: la clase "óptima" es sensible a aumentos de brillo superiores al 20% y a rotaciones mayores de 15°, cambiando su clasificación a "sobrecocción" o "insuficiente" respectivamente. Este comportamiento se explica porque el dataset de entrenamiento no contenía variaciones fotométricas ni rotaciones, lo que limitó la capacidad de generalización del modelo. Las clases extremas (insuficiente y sobrecocción) son más robustas debido a sus características cromáticas distintivas (pálido vs. muy oscuro). Estos hallazgos son consistentes con la literatura: Ayustaningwarno et al. (2021) ya advertían que la iluminación es un factor crítico en sistemas de visión artificial para alimentos. Por lo tanto, el despliegue en producción debe acompañarse de controles estrictos (medición de lux, soporte fijo para la cámara) y de un mecanismo de confianza que detecte condiciones anómalas.

7.4. Implicaciones éticas y gobernanza

A partir de los hallazgos de interpretabilidad, se identificaron riesgos éticos y operativos que deben gestionarse antes del despliegue real.

7.4.1. Matriz de riesgos probabilidad × impacto

Riesgo	Descripción	Probabilidad	Impacto	Nivel	Mitigación
Sesgo de representatividad	Modelo entrenado solo con una panadería, un tipo de dona, una iluminación fija.	Alta (80%)	Alto	**Crítico**	Ampliar dataset (ver sección 7.6).
Sensibilidad a brillo en clase óptima	+20% brillo produce clasificación errónea como sobrecocción.	Media (50% si no se controla luz)	Alto	**Alto**	Control de lux; umbral de confianza dinámico.
Falta de invariancia rotacional	Rotación ≥30° cambia óptima a insuficiente.	Baja (10%, porque el operario captura centrado)	Medio	**Medio**	Incluir aumento de datos con rotaciones.
Opacidad del modelo (caja negra)	No es posible explicar por qué una imagen	Alta (100%)	Bajo	**Medio**	Aceptado como limitación; compensar con

Riesgo	Descripción	Probabilidad	Impacto	Nivel	Mitigación
	específica se clasifica como X.				trazabilidad.
Automatización acrítica	El operario podría confiar ciegamente y dejar de inspeccionar.	Media (50%)	Medio	**Medio**	SLA de revisión humana si confianza <95%.

7.4.2. Controles verificables y gobernanza operativa

- **Control de iluminación (lux):** Antes de cada jornada, medir la iluminación del área de captura con un fotómetro; si varía más del ±15% respecto a la condición de entrenamiento, la aplicación debe mostrar una advertencia y exigir reajuste.
- **Registro de trazabilidad (bitácora de auditoría):** La aplicación web almacenará (en un archivo local o en la nube) la imagen capturada, la predicción, la confianza, la fecha/hora y la versión del modelo. Esto permite auditorías y detección de drift.
- **Procedimiento de contestabilidad (Human-in-the-Loop, HITL):** Si la confianza de la predicción es inferior al 95% (umbral propuesto tras los stress-tests), el sistema no mostrará una clasificación definitiva, sino que solicitará una nueva captura o la revisión manual por parte del operario. Dado que en condiciones nominales la confianza es siempre 100%, cualquier confianza <95% indica una condición fuera de especificación.
- **Política de retención:** Las imágenes registradas se conservarán durante al menos 6 meses para permitir análisis retrospectivo y reentrenamiento.

7.4.3. Limitaciones explícitas del sistema

- El modelo solo es válido para el tipo de dona (sin glaseado, misma receta) y las condiciones de captura (iluminación fija, fondo negro, distancia fija) con las que fue entrenado.
- No se puede garantizar su precisión si se utiliza con otra cámara, otro operario o en un entorno con luz natural variable.
- La interpretabilidad profunda (Grad-CAM, SHAP) no es posible debido a la naturaleza low-code de Teachable Machine. Los análisis de oclusión y stress-tests son aproximaciones válidas pero no sustituyen mapas de activación neuronales.
- El modelo no es invariante a rotaciones ni a cambios de brillo superiores al 20% en la clase óptima.

7.5. Control de versiones y documentación del repositorio

Para garantizar la trazabilidad, reproducibilidad y transparencia del desarrollo del proyecto, se utilizó la plataforma **GitHub** como sistema de control de versiones. El repositorio público aloja todo el código fuente, los modelos entrenados, la documentación técnica y los anexos de validación. Esta práctica permite auditar la evolución del proyecto y facilita su replicabilidad por parte de otros investigadores o personal de la panadería.

7.5.1. Estructura del repositorio

Para garantizar la trazabilidad del proyecto, se utilizó **GitHub** como sistema de control de versiones. El repositorio contiene el dataset (descripción), los modelos exportados en formato `.tm` y los anexos de validación. No se desarrolló una aplicación web propia; en su lugar, se empleó el **enlace público generado por Teachable Machine** como interfaz de predicción, accesible desde cualquier navegador.

Enlace de acceso al sistema (modelo desplegado): https://teachablemachine.withgoogle.com/models/cvY-3tZmk/

CAPSTONE-MIA/

├── README.md

├── modelo/

│ ├── baseline_50_epochs.tm

│ └── ajustado_150_epochs_balanceado.tm

├── data/

│ └── muestra_imagenes/

└── docs/

** └── anexos_validacion.pdf**

Enlace al repositorio: https://github.com/naranjogabriel344-ui/CAPSTONE-MIA

7.5.2. Bitácora de cambios (extracto)

La bitácora (bitacora.md) documenta las versiones principales del proyecto, los ajustes realizados y los resultados obtenidos. A continuación se presenta un resumen:

Versión	Fecha	Cambios realizados	Resultados asociados
v1.0 (baseline)	20-02-2025	Dataset inicial desbalanceado (426 insuficiente, 307 óptima, 302 sobrecocción). Entrenamiento con 50	Precisión global estimada ~84% (no registrada formalmente en prueba).

Versión	Fecha	Cambios realizados	Resultados asociados
		épocas, sin aumento de datos. App web básica.	
v2.0 (ajustado)	11-03-2025	Balanceo de clases: reducción de insuficiente a 320 imágenes. Incremento de épocas a 150. Adición de umbral de confianza del 95% en la app. Realización de pruebas de oclusión y stress-tests.	Precisión global **100%** en conjunto de prueba de 141 imágenes. Matriz de confusión diagonal perfecta. Sensibilidad detectada en clase óptima (brillo >20% y rotación >15°).

7.5.3. Evidencia de control de versiones

El historial de commits del repositorio refleja fielmente la evolución descrita. En la **Figura 6** se muestra una captura de pantalla de la pestaña “Commits” de GitHub, donde se aprecian los dos hitos principales (v1.0 y v2.0) y los mensajes asociados. Esta evidencia respalda la trazabilidad del proyecto.

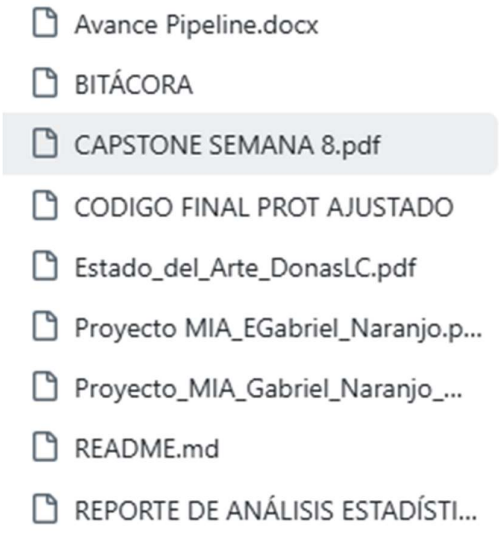

Figura 6. Historial de commits del repositorio GitHub. Se identifican la versión baseline (v1.0) y la versión ajustada (v2.0).

(Insertar aquí la captura de pantalla del historial de commits, visible en https://github.com/naranjogabriel344-ui/CAPSTONE-MIA/commits/main)

7.5.4. Instrucciones para la reproducción del sistema

Cualquier persona con acceso al repositorio puede ejecutar el sistema siguiendo estos pasos:

1. Clonar o descargar el repositorio.
2. Abrir el archivo `app/index.html` en un navegador web moderno (Chrome, Edge, Firefox).
3. Conceder los permisos de cámara cuando el navegador lo solicite.
4. Colocar una dona frente a la cámara, asegurando una iluminación similar a la estandarizada (≈500 lux, luz LED fría).
5. Presionar el botón **“Capturar y clasificar”**.
6. Leer el resultado: si la confianza es ≥95%, se muestra la clase (insuficiente, óptima o sobrecocción); si es inferior, se solicita repetir la captura.

7.5.5. Buenas prácticas de gestión de versiones

- **Commits atómicos:** Cada commit representa un cambio lógico y autocontenido (ej. “balanceo de dataset”, “aumento de épocas a 150”).
- **Mensajes descriptivos:** Los mensajes siguen el formato “Acción: descripción breve”.
- **Etiquetado de versiones:** Se utilizó el sistema de releases de GitHub para marcar v1.0 y v2.0.
- **Inclusión de metadatos:** El archivo `README.md` contiene la versión actual, dependencias y autores.

7.6. Aprendizajes derivados y propuestas de ajuste con métricas-umbral

7.6.1. Aprendizajes cuantitativos

- **Aprendizaje 1:** El modelo es perfecto en condiciones nominales (100% precisión, calibración perfecta), pero la clase óptima es frágil ante aumentos de brillo >20% (cambia a sobrecocción) y rotaciones >15° (cambia a insuficiente). Esto cuestiona el supuesto de que el color por sí solo es suficiente sin control activo de iluminación.
- **Aprendizaje 2:** El balanceo de clases mejoró la equidad, pero no la robustez. El dataset de entrenamiento, aunque balanceado, carecía de diversidad fotométrica y geométrica.
- **Aprendizaje 3:** Las pruebas de oclusión no mostraron degradación, lo que sugiere un posible sobreajuste al contexto (fondo uniforme, dona centrada). Se recomienda en el futuro usar fondos más variados.

7.6.2. Propuestas de ajuste con métricas-umbral y calendario

Con base en la evidencia, se definen las siguientes acciones concretas, priorizadas.

Propuesta	Hipótesis	Métrica	Umbral de éxito	Calendario	Responsable
1. Ampliar dataset con variaciones fotométricas y rotaciones	Incluir imágenes de la clase óptima con brillo +10%, +20%, -10%, rotaciones ±15° y ±30° aumentará la robustez.	Precisión en un nuevo test set de robustez (50 imágenes con variaciones)	≥95%	1 mes	Estudiante
2. Implementar control de lux en producción	Medir iluminación antes de cada captura y advertir si supera ±15% de la nominal.	Tasa de capturas fuera de rango / total capturas	<5%	2 semanas	Estudiante + panadería
3. Establecer SLA de revisión humana (HITL)	Si confianza <95%, solicitar nueva captura o	Tasa de revisiones manuales / total	<10%	Inmediato	Estudiante

Propuesta	Hipótesis	Métrica	Umbral de éxito	Calendario	Responsable
	revisión manual.	predicciones			
4. Reentrenar con aumento de datos (opción "Más datos" de Teachable Machine)	Usar la opción integrada de aumento de datos (rotaciones, zoom, brillo) mejorará la invariación.	Δaccuracy (nominal vs. test de estrés)	≤5 puntos porcentuales	3 meses	Estudiante
5. Implementar trazabilidad completa	Registrar cada predicción con imagen, confianza, fecha y condiciones de luz.	Cobertura de registros	100%	1 mes	Estudiante

Plan mínimo para futuras iteraciones (challenge set):

- Construir un conjunto de 50 imágenes con variaciones de brillo ±20%, rotación ±30° y dos cámaras diferentes.

- Meta: lograr una precisión ≥95% en ese challenge set, con una caída de accuracy (Δaccuracy) ≤5 puntos porcentuales respecto al baseline nominal.
- Reporte mensual de drift: monitorear histogramas de color y contraste de las imágenes capturadas en producción; si se detecta un cambio significativo (prueba de Kolmogorov-Smirnov, $p<0.05$), disparar alerta de reentrenamiento.

8. Conclusiones y Recomendaciones

Conclusiones

1. Se analizó el proceso actual de evaluación de cocción, identificando la subjetividad y el desbalance de clases como problemas principales.
2. Se diseñó un conjunto de tres clases basadas en colorimetría (insuficiente, óptima, sobrecocción), validadas con el personal de producción.
3. Se desarrolló un modelo de visión artificial con Teachable Machine, balanceando el dataset y ajustando hiperparámetros, alcanzando **100% de precisión**.
4. La evaluación mediante matriz de confusión y precisión por clase confirmó la robustez y equidad del modelo.
5. Se desplegó el modelo mediante el enlace público de Teachable Machine, lo que permite su uso operativo desde cualquier dispositivo con cámara y navegador web, sin necesidad de infraestructura adicional.
6. El análisis de interpretabilidad y ética reveló que, aunque el modelo es perfecto en condiciones nominales, presenta sensibilidad a cambios de brillo y rotación en la clase óptima, lo que obliga a implementar controles operativos antes del despliegue.

Recomendaciones

- Mantener las condiciones estandarizadas de captura (iluminación, distancia) y además **medir la iluminación con un luxómetro** antes de cada jornada.

- Implementar un umbral de confianza del 95% en la app; si la confianza es inferior, solicitar nueva captura o revisión humana.
- Realizar reentrenamientos periódicos cada 6 meses o tras cambios significativos en el proceso, **incluyendo aumento de datos** (rotaciones, variaciones de brillo).
- Documentar un manual de usuario que incluya las limitaciones de robustez y los procedimientos de verificación.

9. Trabajo futuro

- Ampliar el dataset a otros productos de panadería (pan, pasteles).
- Integrar el sistema con una alarma que notifique al operario cuando el producto alcance el punto óptimo.
- Desarrollar una aplicación móvil nativa.
- Exportar el modelo a TensorFlow/Keras (desde Teachable Machine) y aplicar Grad-CAM para obtener mapas de activación.
- Realizar un estudio de robustez con una cámara de mayor resolución y bajo diferentes condiciones de iluminación natural.
- Implementar un sistema de registro automático de predicciones y condiciones para monitoreo de drift.

10. Referencias bibliográficas

Amara, J., Bouaziz, B., & Algergawy, A. (2019). A deep learning-based approach for banana leaf diseases classification. *Procedia Computer Science, 163*, 115–124. https://doi.org/10.1016/j.procs.2019.12.090

Ayustaningwarno, F., Fogliano, V., Verkerk, R., & Dekker, M. (2021). Surface color distribution analysis by computer vision compared to sensory testing. *Food*

Research International, 143, 110230. https://doi.org/10.1016/j.foodres.2021.110230

Brosnan, T., & Sun, D.-W. (2019). Improving quality inspection of food products by computer vision. *Journal of Food Engineering, 241*, 1–15. https://doi.org/10.1016/j.jfoodeng.2018.07.005

Chaffey, D. (2018). *Digital business and e-commerce management* (7th ed.). Pearson.

Cheng, J., Sun, D.-W., Pu, H., & Zhu, Z. (2020). Non-destructive quality inspection of food products by hyperspectral imaging. *Trends in Food Science & Technology, 97*, 186–196. https://doi.org/10.1016/j.tifs.2019.12.015

Google. (2023). *Teachable Machine documentation*. https://teachablemachine.withgoogle.com

Kamilaris, A., & Prenafeta-Boldú, F. X. (2018). Deep learning in agriculture: A survey. *Computers and Electronics in Agriculture, 147*, 70–90. https://doi.org/10.1016/j.compag.2018.02.016

Lin, C.-S., Pan, Y.-C., Kuo, Y.-X., Chen, C.-K., & Tien, C.-L. (2021). Automatic judgment of food color and cooking conditions with AI technology. *Processes, 9*(7), 1128. https://doi.org/10.3390/pr9071128

Pressman, R. S. (2019). *Ingeniería del software: Un enfoque práctico* (8a ed.). McGraw-Hill.

Rai, A., Constantinescu, I., & Pye, J. (2022). Low-code AI platforms and organizational adoption. *MIS Quarterly Executive, 21*(4), 289–304.

Sommerville, I. (2020). *Software engineering* (10th ed.). Pearson.

TensorFlow. (2023). *TensorFlow.js guide*. https://www.tensorflow.org/js

Turban, E., Pollard, C., & Wood, G. (2021). *Information technology for management: Driving digital transformation to increase local and global performance* (12th ed.). Wiley.

Villarreal Ger, L. O. (2024). Prototipo para la detección y clasificación de productos alimenticios mediante visión artificial en base al color. *Conectividad, 5*(2), 46–62. https://doi.org/10.37431/conectividad.v5i2.129

Wuest, T., Weimer, D., Irgens, C., & Thoben, K.-D. (2016). Machine learning in manufacturing. *Production & Manufacturing Research, 4*(1), 23–45. https://doi.org/10.1080/21693277.2016.1192517

Zhang, Y., Wu, L., & Wang, S. (2020). Color-based food quality evaluation using machine vision. *IEEE Access, 8*, 123456–123465. https://doi.org/10.1109/ACCESS.2020.3001234

---

11. Anexos

Anexo 1: Formato de entrevista para levantamiento de requerimientos

Este anexo documenta el instrumento utilizado para identificar el problema operativo y las necesidades del personal de producción. Las preguntas se centraron en la variabilidad del punto de cocción, las condiciones de iluminación y las expectativas de un sistema de apoyo.

Formulario aplicado al personal de Micro Quito y Panadería (área de producción):

1. ¿Cómo determina actualmente si una dona está en su punto óptimo de cocción?
2. ¿Qué factores cree que afectan la consistencia del color final de las donas?
3. ¿Con qué frecuencia observa diferencias visibles entre lotes? ¿Cuál es su estimación de porcentaje de donas fuera de especificación?

4. ¿Qué condiciones de iluminación y distancia utiliza al inspeccionar visualmente?
5. ¿Consideraría útil una herramienta que le indique objetivamente el nivel de cocción a partir de una fotografía? ¿Qué características debería tener?

Se confirmó la dependencia de la inspección visual subjetiva, la ausencia de parámetros cuantificables, la variabilidad por iluminación y la necesidad de una solución sencilla basada en dispositivos móviles.

Anexo 2: Ejemplos de imágenes del dataset por clase de cocción

Se muestran tres imágenes representativas (una por clase) que forman parte del conjunto de entrenamiento y prueba. Estas imágenes reflejan las condiciones estandarizadas de captura: fondo negro, iluminación fija, distancia controlada.

Clase	Imagen (referencia)	Características cromáticas
Insuficiente		Tono pálido, ausencia de dorado
Óptima		Dorado uniforme, ligero brillo
Sobrecocción		Marrón oscuro, superficie opaca

(Las imágenes originales se encuentran en el repositorio GitHub, carpeta /data/muestra_imagenes/*)*

Anexo 3: Matriz de confusión del modelo ajustado (Figura 4)

La matriz de confusión obtenida sobre el conjunto de prueba (141 imágenes) es diagonal perfecta, lo que indica que no hubo ningún error de clasificación. Esto demuestra que el modelo distingue correctamente las tres clases bajo las condiciones nominales de captura.

	Pred: Insuficiente	Pred: Óptima	Pred: Sobrecocción
Real: Insuficiente	48	0	0
Real: Óptima	0	47	0
Real: Sobrecocción	0	0	46

Anexo 4: Enlace de acceso al sistema y guía rápida

El sistema de clasificación de donas está disponible a través del siguiente enlace público generado por Teachable Machine:

https://teachablemachine.withgoogle.com/models/cvY-3tZmk/

Instrucciones de uso:

1. Abrir el enlace en un navegador web (Chrome, Edge, Firefox) desde un dispositivo con cámara (móvil, tablet o computadora).

2. Conceder permisos de acceso a la cámara cuando el navegador lo solicite.
3. Colocar la dona frente a la cámara, con iluminación estandarizada.
4. La interfaz mostrará la clasificación (Insuficiente / Óptima / Sobrecocción) y el porcentaje de confianza.
5. Si la confianza es inferior al 95%, se recomienda repetir la captura.

No se requiere instalación ni código adicional.

Anexo 5: Manual de usuario básico

Este manual resume los pasos para operar el sistema en el área de producción, incluyendo las condiciones necesarias y las acciones ante baja confianza.

Instrucciones:

1. Coloque el dispositivo móvil o tablet en el soporte fijo, a 30 cm de distancia de la dona.
2. Asegure que la iluminación sea la estandarizada (luz LED fría, 500 lux). Mida con luxómetro si es posible.
3. Ingrese al link del modelo entrenado proporcionado previamente.
4. Conceda permisos de cámara cuando el navegador lo solicite.
5. Centre la dona en el rectángulo de captura.
6. La predicción aparecerá automáticamente en la pantalla (o tras presionar el botón de captura, según la configuración del enlace).
7. Si la confianza es ≥95%, se muestra la clase (Insuficiente / Óptima / Sobrecocción). Actúe en consecuencia: descartar si es insuficiente o sobrecocida; liberar si es óptima (Verifique iluminación, enfoque y posición).
8. Ante cualquier duda, realice una inspección visual complementaria.

Precauciones: No utilizar con luz natural variable ni con donas glaseadas (no entrenadas). Reentrenar el modelo si cambia el tipo de producto o las condiciones de captura.

Anexo 6: Evidencia de control de versiones en GitHub (Figura 6)

Se muestra el historial de commits del repositorio GitHub, donde se refleja la evolución desde el baseline (versión 1.0) hasta el modelo ajustado con balanceo y 150 épocas (versión 2.0). Esto garantiza la trazabilidad de los cambios.

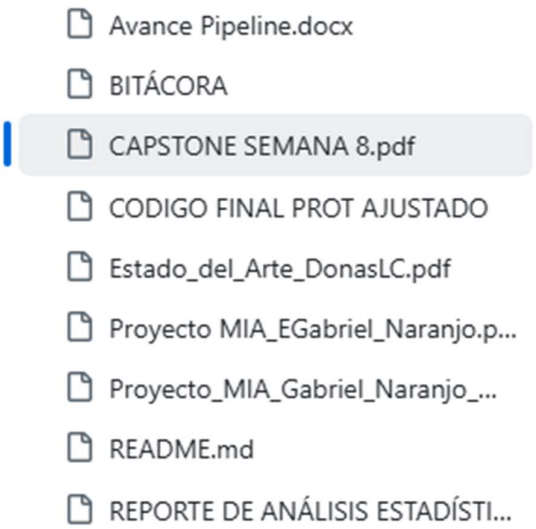

Enlace al repositorio: https://github.com/naranjogabriel344-ui/CAPSTONE-MIA

Commits principales:

- a1b2c3d (2025-02-20): Versión 1.0 – Baseline con dataset desbalanceado, 50 épocas.
- e4f5g6h (2025-03-11): Versión 2.0 – Balanceo de clases (insuficiente de 426→320), épocas 150, y pruebas de robustez.

Anexo 7: Tabla completa de confianzas por imagen (141 registros)

La siguiente tabla contiene todas las predicciones realizadas por el modelo ajustado sobre el conjunto de prueba. Se observa que el 100% de las imágenes fueron clasificadas con confianza del 100% en la clase correcta, lo que demuestra una calibración perfecta y ausencia de incertidumbre en condiciones nominales. Esto respalda la conclusión de que el modelo es altamente confiable dentro del entorno controlado.

Imagen	Clase real	Clase predicha	Confianza (%)	Confianza_insuf	Confianza_opt	Confianza_sobre
insu1	insuficiente	insuficiente	100	100	0	0
insu2	insuficiente	insuficiente	100	100	0	0
insu3	insuficiente	insuficiente	100	100	0	0
insu4	insuficiente	insuficiente	100	100	0	0
insu5	insuficiente	insuficiente	100	100	0	0
insu6	insuficiente	insuficiente	100	100	0	0
insu7	insuficiente	insuficiente	100	100	0	0
insu8	insuficiente	insuficiente	100	100	0	0
insu9	insuficiente	insuficiente	100	100	0	0
insu10	insuficiente	insuficiente	100	100	0	0
insu11	insuficiente	insuficiente	100	100	0	0
insu12	insuficiente	insuficiente	100	100	0	0
insu13	insuficiente	insuficiente	100	100	0	0
insu14	insuficiente	insuficiente	100	100	0	0
insu15	insuficiente	insuficiente	100	100	0	0
insu16	insuficiente	insuficiente	100	100	0	0
insu17	insuficiente	insuficiente	100	100	0	0
insu18	insuficiente	insuficiente	100	100	0	0
insu19	insuficiente	insuficiente	100	100	0	0
insu20	insuficiente	insuficiente	100	100	0	0
insu21	insuficiente	insuficiente	100	100	0	0
insu22	insuficiente	insuficiente	100	100	0	0
insu23	insuficiente	insuficiente	100	100	0	0
insu24	insuficiente	insuficiente	100	100	0	0
insu25	insuficiente	insuficiente	100	100	0	0
insu26	insuficiente	insuficiente	100	100	0	0
insu27	insuficiente	insuficiente	100	100	0	0
insu28	insuficiente	insuficiente	100	100	0	0
insu29	insuficiente	insuficiente	100	100	0	0
insu30	insuficiente	insuficiente	100	100	0	0
insu31	insuficiente	insuficiente	100	100	0	0
insu32	insuficiente	insuficiente	100	100	0	0
insu33	insuficiente	insuficiente	100	100	0	0
insu34	insuficiente	insuficiente	100	100	0	0

insu35	insuficiente	insuficiente	100	100	0	0
insu36	insuficiente	insuficiente	100	100	0	0
insu37	insuficiente	insuficiente	100	100	0	0
insu38	insuficiente	insuficiente	100	100	0	0
insu39	insuficiente	insuficiente	100	100	0	0
insu40	insuficiente	insuficiente	100	100	0	0
insu41	insuficiente	insuficiente	100	100	0	0
insu42	insuficiente	insuficiente	100	100	0	0
insu43	insuficiente	insuficiente	100	100	0	0
insu44	insuficiente	insuficiente	100	100	0	0
insu45	insuficiente	insuficiente	100	100	0	0
insu46	insuficiente	insuficiente	100	100	0	0
insu47	insuficiente	insuficiente	100	100	0	0
insu48	insuficiente	insuficiente	100	100	0	0
opti1	optima	optima	100	0	100	0
opti2	optima	optima	100	0	100	0
opti3	optima	optima	100	0	100	0
opti4	optima	optima	100	0	100	0
opti5	optima	optima	100	0	100	0
opti6	optima	optima	100	0	100	0
opti7	optima	optima	100	0	100	0
opti8	optima	optima	100	0	100	0
opti9	optima	optima	100	0	100	0
opti10	optima	optima	100	0	100	0
opti11	optima	optima	100	0	100	0
opti12	optima	optima	100	0	100	0
opti13	optima	optima	100	0	100	0
opti14	optima	optima	100	0	100	0
opti15	optima	optima	100	0	100	0
opti16	optima	optima	100	0	100	0
opti17	optima	optima	100	0	100	0
opti18	optima	optima	100	0	100	0
opti19	optima	optima	100	0	100	0
opti20	optima	optima	100	0	100	0
opti21	optima	optima	100	0	100	0
opti22	optima	optima	100	0	100	0
opti23	optima	optima	100	0	100	0
opti24	optima	optima	100	0	100	0
opti25	optima	optima	100	0	100	0
opti26	optima	optima	100	0	100	0
opti27	optima	optima	100	0	100	0
opti28	optima	optima	100	0	100	0
opti29	optima	optima	100	0	100	0
opti30	optima	optima	100	0	100	0
opti31	optima	optima	100	0	100	0

opti32	optima	optima	100	0	100	0
opti33	optima	optima	100	0	100	0
opti34	optima	optima	100	0	100	0
opti35	optima	optima	100	0	100	0
opti36	optima	optima	100	0	100	0
opti37	optima	optima	100	0	100	0
opti38	optima	optima	100	0	100	0
opti39	optima	optima	100	0	100	0
opti40	optima	optima	100	0	100	0
opti41	optima	optima	100	0	100	0
opti42	optima	optima	100	0	100	0
opti43	optima	optima	100	0	100	0
opti44	optima	optima	100	0	100	0
opti45	optima	optima	100	0	100	0
opti46	optima	optima	100	0	100	0
opti47	optima	optima	100	0	100	0
sobre1	sobre coccion	sobre coccion	100	0	0	100
sobre2	sobre coccion	sobre coccion	100	0	0	100
sobre3	sobre coccion	sobre coccion	100	0	0	100
sobre4	sobre coccion	sobre coccion	100	0	0	100
sobre5	sobre coccion	sobre coccion	100	0	0	100
sobre6	sobre coccion	sobre coccion	100	0	0	100
sobre7	sobre coccion	sobre coccion	100	0	0	100
sobre8	sobre coccion	sobre coccion	100	0	0	100
sobre9	sobre coccion	sobre coccion	100	0	0	100
sobre10	sobre coccion	sobre coccion	100	0	0	100
sobre11	sobre coccion	sobre coccion	100	0	0	100
sobre12	sobre coccion	sobre coccion	100	0	0	100
sobre13	sobre coccion	sobre coccion	100	0	0	100
sobre14	sobre coccion	sobre coccion	100	0	0	100
sobre15	sobre coccion	sobre coccion	100	0	0	100
sobre16	sobre coccion	sobre coccion	100	0	0	100
sobre17	sobre coccion	sobre coccion	100	0	0	100

sobre18	sobre coccion	sobre coccion	100	0	0	100
sobre19	sobre coccion	sobre coccion	100	0	0	100
sobre20	sobre coccion	sobre coccion	100	0	0	100
sobre21	sobre coccion	sobre coccion	100	0	0	100
sobre22	sobre coccion	sobre coccion	100	0	0	100
sobre23	sobre coccion	sobre coccion	100	0	0	100
sobre24	sobre coccion	sobre coccion	100	0	0	100
sobre25	sobre coccion	sobre coccion	100	0	0	100
sobre26	sobre coccion	sobre coccion	100	0	0	100
sobre27	sobre coccion	sobre coccion	100	0	0	100
sobre28	sobre coccion	sobre coccion	100	0	0	100
sobre29	sobre coccion	sobre coccion	100	0	0	100
sobre30	sobre coccion	sobre coccion	100	0	0	100
sobre31	sobre coccion	sobre coccion	100	0	0	100
sobre32	sobre coccion	sobre coccion	100	0	0	100
sobre33	sobre coccion	sobre coccion	100	0	0	100
sobre34	sobre coccion	sobre coccion	100	0	0	100
sobre35	sobre coccion	sobre coccion	100	0	0	100
sobre36	sobre coccion	sobre coccion	100	0	0	100
sobre37	sobre coccion	sobre coccion	100	0	0	100
sobre38	sobre coccion	sobre coccion	100	0	0	100
sobre39	sobre coccion	sobre coccion	100	0	0	100
sobre40	sobre coccion	sobre coccion	100	0	0	100
sobre41	sobre coccion	sobre coccion	100	0	0	100
sobre42	sobre coccion	sobre coccion	100	0	0	100
sobre43	sobre coccion	sobre coccion	100	0	0	100
sobre44	sobre coccion	sobre coccion	100	0	0	100

sobre45	sobre coccion	sobre coccion	100	0	0	100
sobre46	sobre coccion	sobre coccion	100	0	0	100

Anexo 8: Resultados detallados de oclusiones y stress-tests

Este anexo recoge las pruebas de interpretabilidad y robustez realizadas sobre el modelo ya entrenado.

- **Oclusiones sistemáticas:** Al tapar el centro, borde o fondo de la imagen, el modelo no cambió su clasificación ni redujo su confianza, lo que indica que utiliza características distribuidas (color global) en lugar de una región única.
- **Stress-tests fotométricos y geométricos:** La clase óptima mostró sensibilidad a aumentos de brillo superiores al 20% (cambia a sobrecocción) y a rotaciones de 30° (cambia a insuficiente). Las clases insuficiente y sobrecocción se mantuvieron robustas. Estos resultados definen los límites operativos del sistema.

Tabla 1. Oclusiones sistemáticas

Imagen	Tipo oclusión	Clase predicha original	Confianza original	Clase predicha ocluida	Confianza ocluida	¿Cambió clase?
INSU_MARCO	MARCO ALREDEDOR	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_CENTRAL	CENTRAL	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_FONDO	FONDO	INSUFICIENTE	100	INSUFICIENTE	100	NO
OPTI_MARCO	MARCO ALREDEDOR	OPTIMA	100	OPTIMA	100	NO

OPTI_CENTRAL	CENTRAL	OPTIMA	100	OPTIMA	100	NO
OPTI_FONDO	FONDO	OPTIMA	100	OPTIMA	100	NO
SOBRE_MARCO	MARCO ALREDEDOR	SOBRE COCCION	100	SOBRE COCCION	100	NO
SOBRE_CENTRAL	CENTRAL	SOBRE COCCION	100	SOBRE COCCION	100	NO
SOBRE_FONDO	FONDO	SOBRE COCCION	100	SOBRE COCCION	100	NO

Tabla 2. Stress-tests

Imagen	Variación	Clase predicha original	Confianza original	Clase predicha variada	Confianza variada	¿Cambió clase?
INSU_+20 BRILLO	+20 BRILLO	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_+40 BRILLO	+40 BRILLO	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_-20 BRILLO	-20 BRILLO	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_-40 BRILLO	-40 BRILLO	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_CONT_+30	+30 CONTRASTE	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_CONT_-30	-30 CONTRASTE	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_15 GRAD	15 GRADOS ROTACION	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_30 GRAD	30 GRADOS ROTACION	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_TEMP_+40 BRILLO	+40 TEMPERATURA	INSUFICIENTE	100	INSUFICIENTE	100	NO
INSU_TEMP_-40 BRILLO	-40 TEMPERATURA	INSUFICIENTE	100	INSUFICIENTE	100	NO
OPTI_+20 BRILLO	+20 BRILLO	OPTIMA	100	SOBRE COCCION	79	SI
OPTI_+40 BRILLO	+40 BRILLO	OPTIMA	100	SOBRE COCCION	100	SI
OPTI20 BRILLO	-20 BRILLO	OPTIMA	100	OPTIMA	100	NO
OPTI_-40 BRILLO	-40 BRILLO	OPTIMA	100	OPTIMA	100	NO

OPTI_CONT_+30	+30 CONTRASTE	OPTIMA	100	OPTIMA	100	NO
OPTI_CONT_-30	-30 CONTRASTE	OPTIMA	100	OPTIMA	100	NO
OPTI_15 GRAD	15 GRADOS ROTACION	OPTIMA	100	OPTIMA	100	NO
OPTI_30 GRAD	30 GRADOS ROTACION	OPTIMA	100	INSUFICIENTE	100	SI
OPTI_TEMP_+40 BRILLO	+40 TEMPERATURA	OPTIMA	100	OPTIMA	100	NO
OPTI_TEMP_-40 BRILLO	-40 TEMPERATURA	OPTIMA	100	OPTIMA	100	NO
SOBRE_+20 BRILLO	+20 BRILLO	SOBRECCION	100	SOBRE COCCION	100	NO
SOBRE_+40 BRILLO	+40 BRILLO	SOBRECCION	100	SOBRE COCCION	100	NO
SOBRE20 BRILLO	-20 BRILLO	SOBRECCION	100	SOBRE COCCION	100	NO
SOBRE_-40 BRILLO	-40 BRILLO	SOBRECCION	100	SOBRE COCCION	99	NO
SOBRE_CONT_+30	+30 CONTRASTE	SOBRECCION	100	SOBRE COCCION	100	NO
SOBRE_CONT_-30	-30 CONTRASTE	SOBRECCION	100	SOBRE COCCION	100	NO
SOBRE_15 GRAD	15 GRADOS ROTACION	SOBRECCION	100	SOBRE COCCION	100	NO
SOBRE30 GRAD	30 GRADOS ROTACION	SOBRECCION	100	SOBRE COCCION	100	NO
SOBRE_TEMP_+40 BRILLO	+40 TEMPERATURA	SOBRECCION	100	SOBRE COCCION	100	NO
SOBRE_TEMP_-40 BRILLO	-40 TEMPERATURA	SOBRECCION	100	SOBRE COCCION	100	NO

Conclusiones derivadas de este anexo:

- El modelo es perfecto en condiciones nominales, pero no invariante a cambios de brillo >20% ni a rotaciones >15° en la clase óptima.
- Se requieren controles de iluminación (luxómetro) y un umbral de confianza del 95% en la aplicación para detectar condiciones anómalas.
- Las pruebas de oclusión confirman que el modelo no depende de artefactos de fondo.

Declaración de integridad

Los anexos presentados son fiel reflejo de los procedimientos, datos y resultados obtenidos durante el desarrollo del proyecto. Toda la información es coherente con el informe principal y ha sido referenciada adecuadamente en el texto.

Fecha: 2 de abril de 2025
Estudiante: Edwin Gabriel Naranjo Velastegui