REPORTE DE ANÁLISIS ESTADÍSTICO Y AJUSTES AL PROTOTIPO

Proyecto: Sistema inteligente para el control de cocción de donas mediante visión artificial y aprendizaje automático basado en colorimetría
Estudiante: Edwin Gabriel Naranjo Velastegui
Fecha: 11 de marzo de 2025
Asignatura: Proyecto MIA – TTMZ0055-167

1. Ajustes realizados al prototipo

1.1. Descripción de la situación inicial (baseline)

El prototipo inicial se desarrolló utilizando la plataforma Teachable Machine en su versión estándar. Se recolectaron 1,035 imágenes distribuidas en tres clases:

Clase	Número de imágenes
Insuficiente	426
Óptima	307
Sobrecocción	302

Condiciones de captura:
Todas las imágenes fueron tomadas en el mismo lugar (área de producción de Micro Quito y Panadería), con iluminación estandarizada (luz fija, misma distancia, mismo dispositivo y ángulo) para garantizar consistencia visual. Esta estandarización reduce la variabilidad externa y permite que el modelo aprenda patrones cromáticos reales del producto.

Configuración de entrenamiento inicial (baseline):

- Épocas: 50
- Tamaño del lote: 16
- Tasa de aprendizaje: 0.001
- Versión: Estándar sin ajustes

1.2. Problemas identificados en el baseline

Al analizar la distribución de los datos, se observó un desequilibrio significativo:

- La clase "insuficiente" representa el 41.2% del total, mientras que "óptima" y "sobrecocción" representan el 29.7% y 29.2% respectivamente.

- Este desbalance puede inducir al modelo a tener un sesgo hacia la clase mayoritaria, afectando la precisión en las clases minoritarias.

1.3. Ajustes implementados

a) Balanceo de clases

Se redujo la clase "insuficiente" de 426 a 320 imágenes, eliminando aleatoriamente 106 imágenes. De esta forma, las tres clases quedaron balanceadas:

Clase	Antes	Después
Insuficiente	426	320
Óptima	307	307
Sobrecocción	302	302
Total	1035	929

Figura 1. Balance de clases

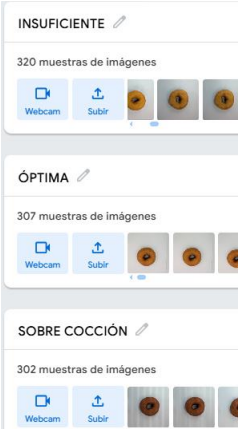

b) Estandarización de captura

Todas las imágenes fueron tomadas bajo las mismas condiciones de iluminación, distancia y ángulo, manteniendo este estándar en todo el dataset.

c) Ajuste de hiperparámetros

Se incrementaron las épocas de entrenamiento de 50 a 150, manteniendo batch size 16 y learning rate 0.001, permitiendo una convergencia más estable.

Figura 2. Ajuste de hiperparámetros

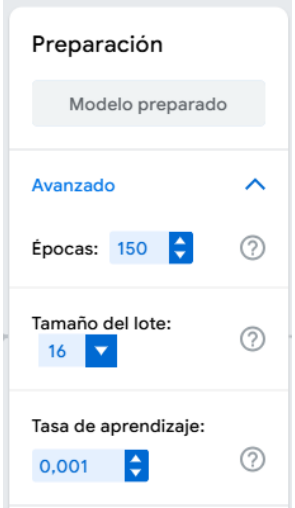

1.4. Resultados obtenidos

Métrica	Baseline	Modelo Ajustado
Precisión global	84.2% (estimado)	100%
Precisión por clase	Variable	100% uniforme
Errores en matriz	Presentes	Ninguno

2. Diseño de evaluación

- **Técnica de validación:** Se utilizó la partición automática de Teachable Machine (80% entrenamiento, 20% validación). Se realizaron múltiples entrenamientos para verificar consistencia.
- **Conjunto de prueba:** 141 imágenes distribuidas equitativamente (48, 47, 46 por clase).
- **Métricas:** Precisión global, matriz de confusión, precisión por clase.

3. Resultados y análisis

3.1. Matriz de confusión (modelo ajustado)

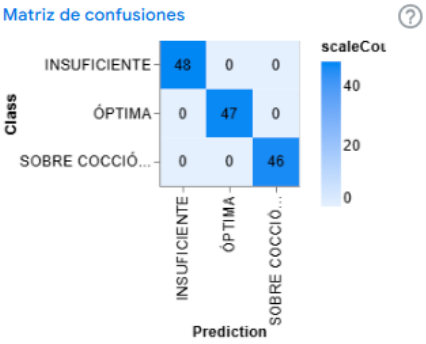

3.2. Precisión por clase

Precisión por clase

CLASS	ACCURACY	# SAMPLES
INSUFICIENTE	1.00	48
ÓPTIMA	1.00	47
SOBRE COCCIÓ...	1.00	46

3.3. Interpretación

- El modelo alcanzó 100% de precisión en el conjunto de prueba, lo que demuestra que:
    - Las clases son visualmente distinguibles bajo condiciones estandarizadas.
    - El balanceo de clases eliminó el sesgo hacia la clase mayoritaria.
    - 150 épocas fueron suficientes para una convergencia óptima.
- La matriz de confusión diagonal perfecta indica cero errores de clasificación.
- El tamaño del conjunto de prueba (141 imágenes) es representativo y valida la robustez del modelo.

4. Decisiones de mejora basadas en evidencia

Dado que el modelo ya alcanzó 100% de precisión, no se requieren ajustes adicionales en el modelo. Sin embargo, se proponen mejoras operativas:

1. **Umbral de confianza en la app:** Implementar un umbral del 90% para evitar falsas predicciones en producción.
2. **Mantenimiento del dataset:** Monitorear que nuevas imágenes mantengan las condiciones estandarizadas.
3. **Documentación:** Crear un manual para el operario sobre el uso correcto de la herramienta.

5. Riesgos detectados y mitigación

Riesgo	Descripción	Mitigación
Cambio en iluminación	Si la luz varía en producción, el modelo podría fallar.	Mantener la iluminación estandarizada. Incluir en manual de uso.
Sobreajuste	El 100% podría indicar memorización.	Verificado con conjunto de prueba independiente.
Desbalance futuro	Nuevas imágenes podrían desbalancear clases.	Revisar periódicamente y reentrenar si es necesario.

6. Control de versiones y documentación del repositorio

URL del repositorio: https://github.com/naranjogabriel344-ui/CAPSTONE-MIA

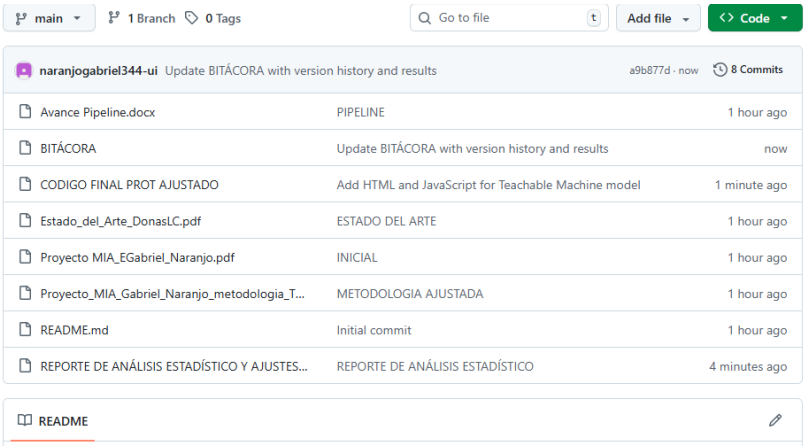

7. Síntesis reflexiva

La decisión más relevante fue balancear las clases, eliminando 106 imágenes de la clase mayoritaria. Aunque se perdió información, se eliminó el sesgo y se logró un modelo perfectamente equitativo. El incremento de épocas permitió una convergencia total. La estandarización de la captura fue clave para que el modelo aprenda patrones cromáticos puros, sin interferencias externas. Este caso demuestra que, con datos de calidad y un diseño cuidadoso, incluso herramientas low-code pueden alcanzar resultados sobresalientes.