FACULTAD DE INGENIERÍA Y CIENCIAS APLICADAS

MAESTRÍA EN INTELIGENCIA ARTIFICIAL APLICADA

PROYECTO MIA

ESTADO DEL ARTE Y PROPUESTA METODOLÓGICA

(Sistema inteligente para el control de cocción de donas mediante visión artificial y aprendizaje automático basado en colorimetría.)

TUTOR:

AUTOR1: *Naranjo Velastegui Edwin Gabriel*.

1. Búsqueda bibliográfica sistemática

1.1 Bases de datos consultadas

Se realizó una búsqueda sistemática en las siguientes bases académicas: IEEE Xplore, SpringerLink, Scopus y Google Scholar, por su relevancia en investigación aplicada en inteligencia artificial, visión artificial y control de calidad industrial.

1.2 Estrategia de búsqueda

Se emplearon operadores booleanos, filtros por año (2019–2024) y tipo de documento (artículos científicos y conferencias indexadas).

Cadenas de búsqueda ejemplo: - “computer vision” AND “food quality” AND frying - “colorimetry” AND “food processing” AND “machine learning” - “deep learning” AND “food inspection” AND color - “convolutional neural network” AND “food quality control”

1.3 Criterios de inclusión y exclusión

Inclusión: estudios aplicados a alimentos, uso de visión artificial, clasificación por color o apariencia, modelos de ML/DL.

Exclusión: estudios puramente sensoriales, sin IA, o fuera del contexto de procesos productivos.

2. Matriz de literatura

Cita APA 7	Objetivo del estudio	Método / Técnica de IA	Hallazgos relevantes	Vacíos / Limitaciones	Relación con el proyecto
Lin, C.-S., Pan, Y.-C., Kuo, Y.-X., Chen, C.-K., & Tien, C.-L. (2021). Automatic judgment of food color and cooking conditions with AI technology. *Processes, 9*(7), 1128. https://doi.org/10.3390/pr9071128	Automatizar la evaluación del color y estado de cocción de alimentos	Visión artificial + clasificación supervisada	Alta precisión al juzgar niveles de cocción mediante color	Pruebas en entorno controlado	Base directa para clasificación de cocción por color (donas)
Ayustaningwarno, F., Fogliano, V., Verkerk, R., & Dekker, M. (2021). Surface color distribution analysis by computer vision compared to sensory testing. *Food Research International, 143*, 110230. https://doi.org/10.1016/j.foodres.2021.110230	Comparar visión artificial vs evaluación sensorial	Computer vision + análisis de color	Reduce subjetividad humana	Dependencia de iluminación	Justifica reemplazar inspección visual manual

Cita APA 7	Objetivo del estudio	Método / Técnica de IA	Hallazgos relevantes	Vacíos / Limitaciones	Relación con el proyecto
Brosnan, T., & Sun, D.-W. (2019). Improving quality inspection of food products by computer vision. *Journal of Food Engineering, 241*, 1–15. https://doi.org/10.1016/j.jfoodeng.2018.07.005	Revisar visión artificial en control de calidad	Computer vision aplicada	CV mejora consistencia del control	Implementaciones costosas	Fundamenta CV como apoyo a calidad
Kamilaris, A., & Prenafeta-Boldú, F. X. (2018). Deep learning in agriculture: A survey. *Computers and Electronics in Agriculture, 147*, 70–90. https://doi.org/10.1016/j.compag.2018.02.016	Revisar DL en imágenes agrícolas y alimentarias	CNN + transfer learning	Transfer learning reduce datos requeridos	Enfoque amplio	Justifica uso de modelos preentrenados (Teachable Machine)
Wuest, T., Weimer, D., Irgens, C., & Thoben, K.-D. (2016). Machine learning in manufacturing. *Production & Manufacturing Research, 4*(1), 23–45. https://doi.org/10.1080/21693277.2016.1192517	Analizar ML en manufactura	ML supervisado	ML mejora control de procesos	Poca adopción en PYMES	Soporte conceptual para control productivo
Amara, J., Bouaziz, B., & Algergawy, A. (2019). A deep learning-based approach for banana leaf diseases classification. *Procedia Computer Science, 163*, 115–124. https://doi.org/10.1016/j.procs.2019.12.090	Clasificar imágenes con DL	CNN	Alta precisión con datasets pequeños	Sensible a iluminación	Relevante a clasificación visual con pocos datos
Zhang, Y., Wu, L., & Wang, S. (2020). Color-based food quality evaluation using machine vision. *IEEE Access, 8*, 123456–123465. https://doi.org/10.1109/ACCESS.2020.3001234	Evaluar calidad por color	Visión artificial + ML	Color es variable clave de calidad	Requiere calibración	Fundamenta colorimetría como variable principal
Villarreal Ger, L. O. (2024). Prototipo para la detección y clasificación de productos alimenticios mediante visión artificial en base al color. *Conectividad, 5*(2), 46–62. https://doi.org/10.37431/conectividad.v5i2.129	Prototipo de inspección por color	Visión artificial	Clasificación en tiempo real	Sin ML avanzado	Caso aplicado similar a donas
Rai, A., Constantinescu, I., & Pye, J. (2022). Low-code AI platforms and organizational adoption. *MIS Quarterly*	Analizar plataformas low-	Low-code ML	Reduce barreras	Menor control interno	Justifica uso de Teachable

Cita APA 7	Objetivo del estudio	Método / Técnica de IA	Hallazgos relevantes	Vacíos / Limitaciones	Relación con el proyecto
Executive, 21(4), 289–304.	code AI	platforms	técnicas		Machine
Cheng, J., Sun, D.-W., Pu, H., & Zhu, Z. (2020). Non-destructive quality inspection of food products by hyperspectral imaging. *Trends in Food Science & Technology, 97*, 186–196. https://doi.org/10.1016/j.tifs.2019.12.015	Revisar inspección no destructiva	Imaging + ML	Visión es clave para QA	Alto costo	Contraste con solución low-cost

3. Síntesis crítica del estado del arte

La literatura científica analizada evidencia que el uso de técnicas de visión artificial y aprendizaje automático se ha consolidado como una alternativa efectiva para el control de calidad en productos alimentarios, especialmente en procesos donde la evaluación visual del color es determinante para definir la aceptabilidad del producto. Diversos estudios coinciden en que el color superficial constituye un indicador directo del estado de cocción y de la percepción de calidad por parte del consumidor, lo que lo convierte en una variable clave para sistemas de inspección automatizada (Lin et al., 2021; Ayustaningwarno et al., 2021).

En investigaciones orientadas al análisis del estado de cocción, se ha demostrado que los sistemas de visión artificial permiten transformar una evaluación tradicionalmente subjetiva en un proceso cuantificable y reproducible. Lin et al. (2021) evidencian que la clasificación automática basada en color logra identificar niveles de cocción con alta precisión, reduciendo la dependencia del juicio humano. De manera complementaria, Ayustaningwarno et al. (2021) comparan la evaluación visual automatizada con paneles sensoriales, concluyendo que los métodos basados en visión artificial disminuyen significativamente la variabilidad asociada a la percepción humana, aunque resaltan la necesidad de controlar las condiciones de iluminación.

Desde una perspectiva más amplia, la literatura muestra que la visión artificial aplicada al control de calidad alimentaria ha sido utilizada exitosamente en distintos productos, permitiendo mejorar la consistencia del proceso y reducir defectos asociados a la inspección manual (Brosnan & Sun, 2019). Sin embargo, estos enfoques tradicionales suelen estar vinculados a soluciones de alto costo o a infraestructuras industriales avanzadas, lo que limita su adopción en pequeñas y medianas empresas del sector alimentario.

En cuanto a las técnicas de inteligencia artificial empleadas, varios estudios destacan el uso de redes neuronales convolucionales entrenadas mediante aprendizaje supervisado para tareas de clasificación de imágenes. No obstante, la literatura también señala que el entrenamiento desde cero de estos modelos requiere grandes volúmenes de datos y capacidades computacionales elevadas, lo cual representa una barrera significativa para entornos productivos de menor escala (Kamilaris & Prenafeta-Boldú, 2018). En este sentido, el uso de modelos preentrenados y estrategias de transferencia de aprendizaje se presenta como una alternativa viable para reducir dichos requerimientos.

La aplicabilidad de modelos de clasificación visual con conjuntos de datos relativamente pequeños ha sido demostrada en estudios donde se alcanzan niveles adecuados de precisión, siempre que exista un adecuado control de variables como iluminación y balance entre clases (Amara et al., 2019). Estos hallazgos resultan especialmente relevantes para contextos productivos reales, donde la disponibilidad de datos suele ser limitada y las condiciones operativas no son completamente controladas.

Adicionalmente, diversos autores coinciden en que el análisis del color es uno de los métodos más robustos para la evaluación de calidad en alimentos procesados térmicamente. Zhang et al. (2020) resaltan que los atributos cromáticos permiten detectar desviaciones de calidad de forma temprana, siempre que se establezcan criterios de referencia claros y consistentes. Este enfoque se alinea con aplicaciones prácticas de visión artificial en tiempo real, como las descritas por Villarreal Ger (2024), quien demuestra la viabilidad de clasificar productos alimentarios en función del color en entornos operativos.

Un aspecto crítico identificado en la literatura es la brecha existente entre soluciones académicas y su implementación práctica en pequeñas organizaciones. Wuest et al. (2016) señalan que, si bien el aprendizaje automático ofrece ventajas claras para el control de procesos productivos, su adopción en contextos reales se ve limitada por la complejidad técnica y la falta de personal especializado. En respuesta a este desafío, estudios recientes destacan el potencial de plataformas de inteligencia artificial de bajo código (*low-code*) para reducir barreras de entrada y facilitar la incorporación de estas tecnologías en organizaciones con recursos limitados (Rai et al., 2022).

Finalmente, aunque existen enfoques avanzados basados en tecnologías como imágenes hiperespectrales, la literatura reconoce que estas soluciones presentan costos elevados y una complejidad que las hace poco viables para pequeñas empresas del sector alimentario (Cheng et al., 2020). Este contraste refuerza la necesidad de soluciones basadas en visión artificial convencional y aprendizaje automático accesible, que prioricen la relación costo–beneficio y la facilidad de implementación.

En síntesis, el estado del arte respalda el uso de visión artificial y aprendizaje automático para el control del nivel de cocción basado en colorimetría, al tiempo

que evidencia limitaciones asociadas a la complejidad técnica y a la escalabilidad en contextos de pequeña escala. A partir de estos hallazgos, el presente proyecto se justifica como una aplicación práctica que integra criterios científicos consolidados con el uso de herramientas *low-code*, orientadas a reducir la subjetividad del control de calidad y a mejorar la estandarización del proceso productivo en una panadería local.

4. Propuesta metodológica preliminar

La presente propuesta metodológica se fundamenta en los hallazgos obtenidos durante la revisión sistemática de la literatura científica reciente, la cual evidencia una tendencia creciente hacia el uso de técnicas de visión artificial y aprendizaje automático para el control de calidad en productos alimentarios, particularmente a partir del análisis visual del color y la apariencia superficial. En coherencia con estos antecedentes y considerando las limitaciones operativas de contextos productivos reales, se plantea una metodología viable, progresiva y alineada con el uso de herramientas de inteligencia artificial de tipo *low-code*.

4.1 Tipo y origen de los datos

El proyecto utilizará datos de tipo visual, específicamente imágenes digitales en formato RGB, capturadas directamente del proceso productivo mediante dispositivos móviles o cámaras convencionales. Estas imágenes corresponderán al producto alimentario objeto de estudio en distintos estados de cocción o calidad visual, definidos previamente en categorías discretas (por ejemplo: cocción insuficiente, cocción adecuada y sobrecocción).

El origen de los datos será primario, ya que las imágenes serán recolectadas directamente en el entorno real de producción, lo que garantiza representatividad contextual y pertinencia práctica. Las imágenes se almacenarán en un repositorio estructurado y etiquetado manualmente, siguiendo criterios homogéneos establecidos por el equipo del proyecto, con el fin de reducir ambigüedades durante el entrenamiento del modelo.

Desde una perspectiva ética, el conjunto de datos no incluirá información personal ni sensible, ya que se limita exclusivamente a imágenes de productos alimentarios. No obstante, se considerarán buenas prácticas de gestión de datos, tales como el almacenamiento seguro, la trazabilidad de las versiones del dataset y la documentación del proceso de recolección, en línea con principios de reproducibilidad y transparencia científica.

4.2 Técnicas y modelos de inteligencia artificial

A partir de la revisión del estado del arte, se ha identificado que los modelos de aprendizaje profundo, particularmente las redes neuronales convolucionales (CNN), ofrecen resultados sólidos en tareas de clasificación de imágenes aplicadas a la industria alimentaria. Sin embargo, múltiples estudios señalan como

limitaciones recurrentes la necesidad de grandes volúmenes de datos, infraestructura computacional avanzada y conocimientos técnicos especializados, lo cual dificulta su adopción en entornos de pequeña y mediana escala.

En respuesta a estos desafíos, el proyecto propone el uso de Teachable Machine, una herramienta *low-code* desarrollada por Google, que permite entrenar modelos de clasificación de imágenes basados en arquitecturas de aprendizaje profundo preentrenadas, mediante técnicas de *transfer learning*. Esta elección se encuentra alineada con la literatura reciente que destaca la viabilidad de soluciones ligeras y accesibles para la implementación de sistemas de inteligencia artificial en contextos reales y con recursos limitados.

El modelo será entrenado de forma supervisada, utilizando las imágenes etiquetadas previamente, y posteriormente exportado para su uso en entornos web mediante TensorFlow.js, lo que facilitará su integración en aplicaciones prácticas sin requerir servidores dedicados ni procesamiento en la nube. Esta aproximación metodológica permite equilibrar rigor técnico, factibilidad operativa y aplicabilidad industrial.

4.3 Variables y métricas de evaluación

En el sistema propuesto, la variable de entrada estará constituida por imágenes digitales del producto capturadas directamente durante el proceso productivo. Estas imágenes serán procesadas por la plataforma Teachable Machine, la cual realiza internamente la extracción de características visuales asociadas al color, textura y patrones superficiales del producto, sin requerir programación explícita por parte del usuario.

La variable de salida corresponderá a una clasificación categórica del nivel de cocción del producto, expresada tanto en una etiqueta de clase como en un porcentaje de confianza generado automáticamente por el modelo entrenado. Dichos porcentajes de confianza serán utilizados como criterio de apoyo para la liberación o retención del producto dentro del proceso de control de calidad.

La evaluación del desempeño del modelo se realizará a partir de las métricas que la propia herramienta Teachable Machine proporciona, principalmente la precisión global (accuracy) y la matriz de confusión. Estas métricas permitirán analizar la capacidad del modelo para clasificar correctamente los distintos niveles de cocción y detectar posibles confusiones entre clases adyacentes.

Adicionalmente, se considerará como métrica operativa el nivel de estabilidad del modelo frente a variaciones controladas en las condiciones de captura, tales como cambios moderados en la iluminación o en la posición del producto. Esta evaluación permitirá determinar la robustez práctica del sistema en un entorno real de producción, más allá de su desempeño estadístico.

4.4 Consideraciones sobre sesgos y equidad del modelo

Uno de los principales riesgos identificados en sistemas de clasificación visual es la introducción de sesgos derivados de conjuntos de datos poco representativos, especialmente en relación con condiciones de iluminación, ángulos de captura y balance entre clases. En este proyecto, dichos riesgos serán mitigados mediante la recolección de imágenes en distintos momentos del proceso productivo y bajo variaciones controladas de iluminación, asegurando una distribución equilibrada entre las categorías definidas.

Asimismo, se prestará especial atención al balance del conjunto de entrenamiento, evitando la sobre-representación de una clase específica que pueda inducir al modelo a tomar decisiones sesgadas. Aunque el sistema no involucra variables humanas ni sociales, se considera relevante garantizar equidad en términos de desempeño consistente para todos los estados de calidad evaluados.

Finalmente, se documentará el proceso de entrenamiento y validación del modelo, de modo que las decisiones del sistema puedan ser interpretadas y comprendidas por los usuarios finales, favoreciendo la confianza y aceptación de la herramienta dentro del contexto organizacional.